

Entrega final: Proyecto de mejora en la inversión en educación: ¿qué factores están detrás del desempeño estudiantil en matemática?

Grupo Los Parsimoniosos

Table of contents

0.1	Introducción	2
0.2	Marco teórico	2
1	EDA	4
1.1	Auditoría de variables	4
1.2	Barplots categóricos	8
1.2.1	Análisis de los barplots categóricos	9
1.3	Boxplots numéricos	10
1.3.1	Análisis de los boxplots numéricos	10
1.4	Barplots numéricos	13
1.5	Correlaciones lineales	14
1.5.1	Análisis de correlaciones con la tasa de desaprobación (target)	16

0.1 Introducción

El desempeño educativo de los estudiantes es el resultado de un conjunto de factores que interactúan entre sí y que abarcan dimensiones sociales, económicas, familiares, escolares e individuales. En particular, el aprendizaje de la matemática constituye una dimensión relevante del desarrollo educativo, debido a su carácter acumulativo y a su contribución al desarrollo de capacidades analíticas, lógicas y de resolución de problemas.

Comprender los factores asociados al desempeño matemático permite avanzar más allá de la descripción de los resultados obtenidos por los estudiantes y aproximarse a la identificación de las condiciones que se relacionan con un mejor o peor desempeño. Este conocimiento resulta especialmente relevante para la formulación de políticas educativas, dado que permite identificar dimensiones potencialmente susceptibles de intervención y orientar los recursos hacia aquellos factores que presentan una mayor asociación con los resultados de aprendizaje.

El presente trabajo analiza información proveniente de una encuesta realizada por el Instituto Nacional de Evaluación Educativa (INEEd) en 2022, dirigida a estudiantes de educación media de Uruguay. Cada estudiante encuestado debió completar cuatro instancias, dos formularios, uno de contexto y otro socioemocional del alumno, y dos pruebas, una de matemática y una de lectura.

A efectos de este trabajo se decidió excluir del análisis la prueba de lectura, tomando a la prueba de matemática como nuestro target y los formularios de contexto y socioemocional nuestros features. En la economía del conocimiento, formar recursos humanos que manejen adecuadamente la matemática, ayudará a elevar la capacidad de investigación y desarrollo local y por ende mejorar la competitividad del país. Por eso es relevante investigar los resultados que el país está logrando en el desempeño matemático y ejecutar acciones que mejoren ese desempeño.

A partir de esta información, el estudio busca identificar los principales factores asociados al desempeño de los estudiantes en matemática, integrando variables correspondientes a diferentes dimensiones de su experiencia educativa y social. Para ello, se desarrolla un análisis exploratorio de los datos y posteriormente se aplican herramientas de modelización estadística y de aprendizaje automático orientadas a identificar las variables con mayor relevancia para distinguir entre estudiantes que alcanzan o no determinados niveles de desempeño.

Cargando datasets desde INEEd...

0.2 Marco teórico

Marco teórico

El análisis del desempeño educativo se sustenta en diferentes perspectivas teóricas que permiten comprender la influencia de las condiciones en las que se desarrolla el proceso de aprendizaje.

Estas perspectivas no deben entenderse como explicaciones excluyentes, sino como dimensiones complementarias que permiten abordar el fenómeno desde distintos niveles.

1. Enfoque socioeconómico

El enfoque socioeconómico sostiene que el origen social y las condiciones económicas del hogar condicionan las oportunidades educativas de los estudiantes. Las diferencias en los recursos disponibles pueden afectar tanto las condiciones materiales en las que se desarrolla el aprendizaje como el acceso a bienes y oportunidades educativas.

Desde esta perspectiva, variables como el ingreso del hogar, el nivel educativo de los padres, la ocupación de los adultos responsables, las condiciones de vivienda y las situaciones de pobreza pueden estar asociadas al desempeño académico.

La hipótesis general de este enfoque es que los estudiantes que se desarrollan en contextos con mayores recursos económicos y sociales pueden disponer de mejores condiciones para sostener sus trayectorias educativas y enfrentar las exigencias del proceso de aprendizaje.

2. Enfoque familiar y cultural

El enfoque familiar y cultural pone el énfasis en el entorno inmediato del estudiante y en los recursos culturales y sociales disponibles en su hogar. La familia puede contribuir al aprendizaje mediante la generación de hábitos, expectativas y prácticas que favorecen el desarrollo de competencias educativas.

Entre las variables asociadas a esta perspectiva se encuentran la frecuencia de lectura en el hogar, las expectativas familiares, la participación de los padres en la educación, el capital cultural y el capital social.

Desde este enfoque, el desempeño educativo no depende exclusivamente de los recursos económicos disponibles, sino también de las prácticas familiares, las expectativas respecto de la educación y la exposición del estudiante a actividades y recursos que favorecen el aprendizaje.

3. Enfoque escolar

El enfoque escolar centra la atención en las características de las instituciones educativas y en las condiciones en las que se desarrolla el proceso de enseñanza y aprendizaje. Desde esta perspectiva, las diferencias en los resultados educativos pueden estar relacionadas con los recursos y las prácticas de las instituciones a las que concurren los estudiantes.

Entre las principales variables consideradas se encuentran la calidad docente, la infraestructura, los recursos educativos disponibles, el clima escolar, el liderazgo de los equipos de dirección y el tamaño de las clases.

Este enfoque permite incorporar al análisis factores que trascienden las características individuales del estudiante y considerar el papel que desempeña el contexto institucional en la generación de oportunidades de aprendizaje.

4. Enfoque individual

El enfoque individual explica las diferencias en el desempeño a partir de características propias de los estudiantes. Estas características pueden estar vinculadas tanto con sus capacidades cognitivas como con aspectos motivacionales, conductuales y socioemocionales.

Entre las variables relevantes se encuentran la inteligencia y las habilidades cognitivas, la motivación, la autoeficacia, la salud física y mental, los hábitos de estudio y la asistencia a clases.

Desde esta perspectiva, los estudiantes pueden presentar diferentes niveles de desempeño aun cuando compartan un contexto socioeconómico o educativo similar, debido a diferencias en sus habilidades, actitudes, hábitos y experiencias individuales.

1 EDA

1.1 Auditoría de variables

Dimensiones del dataset: 9539 filas × 37 columnas


Table 1: Auditoría de variables del dataset

	dtype	nulos	pct_nulos	valores_únicos	moda	ejemplo
zona	object	0	0	2	Interior	Interior
region	object	0	0	5	SUR	OESTE
departamento_residencia	float64	612	6.42	20	1.0	17.0
categoria_centro	object	0	0	3	Secundaria pública	Secundaria pública
categoria_grupo	object	0	0	4	Secundaria pública	Secundaria pública
alumno_genero	object	93	0.97	3	M	M
ascendencia	float64	612	6.42	6	1.0	5.0
pais_nacimiento	float64	612	6.42	10	1.0	1.0
edad	float64	271	2.84	16	15.0	14.0
idx_inse_alumno	float64	633	6.64	80	39.0	59.0
idx_esec_alumno	float64	0	0	2088	-	1.13252068
					0.465260088	
idx_esec_centro	float64	0	0	339	-	0.253144861
					0.572519159	
idx_esec_grupo	float64	0	0	611	0.291838951	0.194326805
idx_sentido_pertenencia	float64	682	7.15	661	52.05866752	66.05294759
idx_vinculo_entre_estudiantes	float64	652	6.84	1112	56.8411297	62.58278715
idx_vinculo_estudiantes_hispano	float64	660	6.92	1200	68.45730078	58.8271517
idx_vinculo_estudiantes_europeos	float64	660	6.92	1038	52.91900357	57.59073108
idx_voz_estudiante	float64	719	7.54	1286	47.81205577	59.31914609
idx_actitud_lectura	float64	642	6.73	1287	50.99248159	47.97931694
idx_actitud_matematica	float64	642	6.73	1261	69.69321186	53.17895673
idx_autocontrol	float64	566	5.93	871	51.62950532	52.04586659
idx_autoeficacia_idioma_español	float64	548	5.74	457	49.63416354	55.60653476
idx_autoeficacia_matematica	float64	546	5.72	578	66.93139878	55.09028336
idx_autoregulacion_metacognitiva	float64	545	5.71	1834	69.63753503	57.62040334
idx_empatia	float64	556	5.83	762	50.54636186	50.5129388
idx_conductas_externalizadas	float64	566	5.93	2357	36.69760596	36.69760596
idx_habilidades_interpersonales	float64	556	5.83	8016	52.10699388	57.25966215
idx_habilidades_intrapersonales	float64	565	5.92	8122	52.76236567	67.59125912
idx_habilidades_relacionales	float64	557	5.84	1951	52.73257917	57.81965814
idx_conductas_internalizadas	float64	566	5.93	5666	31.60307404	31.60307404
idx_motivacion_aprendizaje	float64	545	5.71	8984	80.21637318	56.49092342
idx_motivacion_intrínseca	float64	553	5.8	606	45.09601091	48.54210895
idx_perseverancia_académica	float64	555	5.82	1459	50.31137625	61.19048543
idx_regulacion_emocional	float64	565	5.92	1941	54.56110568	67.95114666
idx_valoracion_tarea_idioma_español	float64	555	5.77	555	50.56158053	56.77999179

	dtype	nulos	pct_nulos	valores_únicos	moda	ejemplo
idx_valoracion_tarea_matematica	float64	549	5.76	591	47.91484453	51.06986951
target	int64	0	0	2	1.0	1

1.2 Barplots categóricos

Análisis de la tasa de desaprobación según variables categóricas
n = 9,539




1.2.1 Análisis de los barplots categóricos

A partir de los gráficos, se observa que la tasa global de desaprobación en la prueba de Matemática es elevada (88,7%), aunque existen diferencias entre los distintos grupos analizados.

- Zona de residencia: los estudiantes del Interior presentan una tasa de desaprobación superior a la media y mayor que la observada en Montevideo, lo que sugiere una leve brecha territorial en el desempeño.
- Región: se aprecian diferencias moderadas entre regiones. Norte, Este y Oeste exhiben las tasas de desaprobación más altas, mientras que la región Sur presenta la menor proporción de estudiantes desaprobados, ubicándose por debajo de la tasa global.
- Departamento de residencia: existe heterogeneidad entre departamentos. Algunos, como Artigas, muestran tasas de desaprobación cercanas al 97%, mientras que Montevideo y Durazno presentan valores relativamente menores. Sin embargo, en varios departamentos el tamaño muestral es reducido, por lo que esas diferencias deben interpretarse con cautela.
- Género: las diferencias son prácticamente inexistentes. Mujeres y varones presentan tasas de desaprobación muy similares, cercanas a la media, mientras que la categoría “Otro” se ubica levemente por debajo, aunque con un número muy pequeño de casos (n=231).
- Ascendencia: se observan algunas diferencias. Los estudiantes que se identifican con ascendencia asiática o amarilla presentan la mayor tasa de desaprobación, seguidos por quienes reportan ascendencia afro o negra y otra. En contraste, quienes declaran ascendencia blanca muestran la menor tasa de desaprobación del grupo, situándose por debajo de la media global.

1.3 Boxplots numéricos

Análisis de variables cuantitativas vs. Desaprobación / Aprobación (Boxplots)



1.3.1 Análisis de los boxplots numéricos


A partir de los boxplots se observan diferencias claras entre los estudiantes que aprueban (0) y quienes desaprueban (1) la prueba de Matemática para algunos de los índices analizados.

- Estatus del nivel socioeconómico del estudiante: los estudiantes que aprueban presentan, en general, un nivel socioeconómico más alto. La mediana del índice es considerablemente superior en el grupo que aprueba, mientras que quienes desaprueban se concentran en


valores más bajos. Esto sugiere una asociación negativa entre el nivel socioeconómico y la probabilidad de desaprobación.

- Índice del nivel cultural y socioeconómico del estudiante: se observa un patrón similar al anterior. Los estudiantes que aprueban presentan valores positivos y una mediana claramente superior, mientras que quienes desaprueban se concentran en valores inferiores. La diferencia entre ambos grupos es marcada, lo que indica que este índice podría ser un importante factor asociado al desempeño en Matemática.
- Índice de actitud hacia la matemática: los estudiantes que aprueban muestran una actitud más favorable hacia la asignatura, reflejada en una mediana sensiblemente mayor. Aunque existe cierto solapamiento entre ambos grupos, la distribución evidencia que una actitud más positiva hacia la Matemática se asocia con una menor probabilidad de desaprobación.
- Índice de vínculo entre estudiantes y docentes: las distribuciones de ambos grupos son muy similares, con medianas prácticamente iguales y una fuerte superposición de los rangos intercuartílicos. Esto sugiere que, de manera aislada, este indicador presenta una capacidad limitada para diferenciar entre estudiantes que aprueban y desaprueban.
- Índice de sentido de pertenencia: también se observan diferencias reducidas entre ambos grupos. Los estudiantes que aprueban presentan una mediana ligeramente superior, aunque la superposición entre las distribuciones es considerable, por lo que el sentido de pertenencia parece tener una asociación más débil con el resultado de la prueba.

1.4 Barplots numéricos



1.5 Correlaciones lineales



Ranking de correlación de índices socioemocionales vs Target



1.5.1 Análisis de correlaciones con la tasa de desaprobación (target)

- Los factores socioeconómicos y educativos (idx_inse_alumno e idx_esec_alumno) son los que más se asocian (aunque de forma moderada) con la desaprobación: a mejores índices, menor tasa de desaprobación.
- La actitud hacia matemáticas tiene cierta influencia, pero es más débil que los factores estructurales.
- El vínculo con docentes y el sentido de pertenencia tienen una correlación casi nula con la desaprobación, lo que sugiere que, en este contexto, no son factores determinantes para explicar el rendimiento en términos de aprobación/desaprobación.
- No hay correlaciones fuertes (todas están por debajo de 0.4 en valor absoluto), lo que indica que la desaprobación es un fenómeno multifactorial y que estas variables explican solo una parte de su variabilidad.

Durante el análisis exploratorio (EDA), se identificó la presencia de valores atípicos (e.g., códigos 98 y 99) en variables sociodemográficas como la Ascendencia. Dado que el diccionario de datos oficial del INEEd solo categoriza respuestas del 1 al 5, se infirió que estos códigos corresponden a marcas de sistema para ‘No sabe/No contesta’. En consecuencia, fueron transformados a nulos (NaN) para permitir un manejo correcto en el Pipeline de imputación y no distorsionar la evaluación de equidad algorítmica.