

# Entrega final: Proyecto de mejora en la inversión en educación: ¿qué factores están detrás del desempeño estudiantil en matemática?

Grupo Los Parsimoniosos

## Tabla de contenidos

|          |                                                                           |          |
|----------|---------------------------------------------------------------------------|----------|
| 0.1      | Introducción . . . . .                                                    | 2        |
| 0.2      | Marco teórico . . . . .                                                   | 2        |
| 0.3      | Metodología . . . . .                                                     | 4        |
| 0.3.1    | Binarización del desempeño . . . . .                                      | 5        |
| <b>1</b> | <b>1) Reajuste de pesos</b>                                               | <b>7</b> |
| 1.1      | EDA . . . . .                                                             | 8        |
| 1.2      | Auditoría de variables . . . . .                                          | 8        |
| 1.3      | Barplots categóricos . . . . .                                            | 11       |
| 1.3.1    | Análisis de los barplots categóricos . . . . .                            | 12       |
| 1.4      | Boxplots numéricos . . . . .                                              | 13       |
| 1.4.1    | Análisis de los boxplots numéricos . . . . .                              | 13       |
| 1.5      | Barplots numéricos . . . . .                                              | 16       |
| 1.6      | Correlaciones lineales . . . . .                                          | 17       |
| 1.6.1    | Análisis de correlaciones con la tasa de desaprobación (target) . . . . . | 19       |
| 1.7      | Entrenamiento de los modelos . . . . .                                    | 19       |
| 1.7.1    | Categorización de variables . . . . .                                     | 19       |
| 1.7.2    | Column transformers . . . . .                                             | 19       |
| 1.7.3    | Definición de modelos y corrida . . . . .                                 | 19       |
| 1.7.4    | Resultados de los modelos . . . . .                                       | 19       |
| 1.7.5    | Cálculo de Feature y Permutation Importance . . . . .                     | 20       |
| 1.7.6    | Cálculo de RFECV . . . . .                                                | 20       |
| 1.7.7    | Gráficas comparativas . . . . .                                           | 20       |

## 0.1 Introducción

El desempeño educativo de los estudiantes es el resultado de un conjunto de factores que interactúan entre sí y que abarcan dimensiones sociales, económicas, familiares, escolares e individuales. En particular, el aprendizaje de la matemática constituye una dimensión relevante del desarrollo educativo, debido a su carácter acumulativo y a su contribución al desarrollo de capacidades analíticas, lógicas y de resolución de problemas.

Comprender los factores asociados al desempeño matemático permite avanzar más allá de la descripción de los resultados obtenidos por los estudiantes y aproximarse a la identificación de las condiciones que se relacionan con un mejor o peor desempeño. Este conocimiento resulta especialmente relevante para la formulación de políticas educativas, dado que permite identificar dimensiones potencialmente susceptibles de intervención y orientar los recursos hacia aquellos factores que presentan una mayor asociación con los resultados de aprendizaje.

El presente trabajo analiza información proveniente de una encuesta realizada por el Instituto Nacional de Evaluación Educativa (INEEd) en 2022, dirigida a estudiantes de educación media de Uruguay. Cada estudiante encuestado debió completar cuatro instancias, dos formularios, uno de contexto y otro socioemocional del alumno, y dos pruebas, una de matemática y una de lectura.

A efectos de este trabajo se decidió excluir del análisis la prueba de lectura, tomando a la prueba de matemática como nuestro target y los formularios de contexto y socioemocional nuestros features. En la economía del conocimiento, formar recursos humanos que manejen adecuadamente la matemática, ayudará a elevar la capacidad de investigación y desarrollo local y por ende mejorar la competitividad del país. Por eso es relevante investigar los resultados que el país está logrando en el desempeño matemático y ejecutar acciones que mejoren ese desempeño.

A partir de esta información, el estudio busca identificar los principales factores asociados al desempeño de los estudiantes en matemática, integrando variables correspondientes a diferentes dimensiones de su experiencia educativa y social. Para ello, se desarrolla un análisis exploratorio de los datos y posteriormente se aplican herramientas de modelización estadística y de aprendizaje automático orientadas a identificar las variables con mayor relevancia para distinguir entre estudiantes que alcanzan o no determinados niveles de desempeño.

## 0.2 Marco teórico

El análisis del desempeño educativo se sustenta en diferentes perspectivas teóricas que permiten comprender la influencia de las condiciones en las que se desarrolla el proceso de aprendizaje. Estas perspectivas no deben entenderse como explicaciones excluyentes, sino como dimensiones complementarias que permiten abordar el fenómeno desde distintos niveles.

1. Enfoque socioeconómico

El enfoque socioeconómico sostiene que el origen social y las condiciones económicas del hogar condicionan las oportunidades educativas de los estudiantes. Las diferencias en los recursos disponibles pueden afectar tanto las condiciones materiales en las que se desarrolla el aprendizaje como el acceso a bienes y oportunidades educativas.

Desde esta perspectiva, variables como el ingreso del hogar, el nivel educativo de los padres, la ocupación de los adultos responsables, las condiciones de vivienda y las situaciones de pobreza pueden estar asociadas al desempeño académico.

La hipótesis general de este enfoque es que los estudiantes que se desarrollan en contextos con mayores recursos económicos y sociales pueden disponer de mejores condiciones para sostener sus trayectorias educativas y enfrentar las exigencias del proceso de aprendizaje.

## 2. Enfoque familiar y cultural

El enfoque familiar y cultural pone el énfasis en el entorno inmediato del estudiante y en los recursos culturales y sociales disponibles en su hogar. La familia puede contribuir al aprendizaje mediante la generación de hábitos, expectativas y prácticas que favorecen el desarrollo de competencias educativas.

Entre las variables asociadas a esta perspectiva se encuentran la frecuencia de lectura en el hogar, las expectativas familiares, la participación de los padres en la educación, el capital cultural y el capital social.

Desde este enfoque, el desempeño educativo no depende exclusivamente de los recursos económicos disponibles, sino también de las prácticas familiares, las expectativas respecto de la educación y la exposición del estudiante a actividades y recursos que favorecen el aprendizaje.

## 3. Enfoque escolar

El enfoque escolar centra la atención en las características de las instituciones educativas y en las condiciones en las que se desarrolla el proceso de enseñanza y aprendizaje. Desde esta perspectiva, las diferencias en los resultados educativos pueden estar relacionadas con los recursos y las prácticas de las instituciones a las que concurren los estudiantes.

Entre las principales variables consideradas se encuentran la calidad docente, la infraestructura, los recursos educativos disponibles, el clima escolar, el liderazgo de los equipos de dirección y el tamaño de las clases.

Este enfoque permite incorporar al análisis factores que trascienden las características individuales del estudiante y considerar el papel que desempeña el contexto institucional en la generación de oportunidades de aprendizaje.

## 4. Enfoque individual

El enfoque individual explica las diferencias en el desempeño a partir de características propias de los estudiantes. Estas características pueden estar vinculadas tanto con sus capacidades cognitivas como con aspectos motivacionales, conductuales y socioemocionales.

Entre las variables relevantes se encuentran la inteligencia y las habilidades cognitivas, la motivación, la autoeficacia, la salud física y mental, los hábitos de estudio y la asistencia a clases.

Desde esta perspectiva, los estudiantes pueden presentar diferentes niveles de desempeño aun cuando compartan un contexto socioeconómico o educativo similar, debido a diferencias en sus habilidades, actitudes, hábitos y experiencias individuales.

### **0.3 Metodología**

#### **1. Fuente de información y diseño de la encuesta**

Como se mencionó, el desarrollo de la investigación se utilizó la información correspondiente a Aristas Media 2022, evaluación realizada por el Instituto Nacional de Evaluación Educativa (INEEd) a estudiantes que cursaban el último año del ciclo básico de educación media en Uruguay.

La encuesta comprende estudiantes pertenecientes a centros educativos de carácter público y privado de todo el país, incluyendo instituciones de educación secundaria y centros de la UTU. El diseño de la muestra es de carácter estratificado, lo que implica que la población estudiantil fue dividida previamente en grupos o estratos definidos a partir de determinadas características relevantes para el diseño muestral. Posteriormente, se seleccionaron unidades dentro de cada estrato, procurando garantizar la representación de los distintos contextos educativos y geográficos de la población objetivo.

Como consecuencia de este diseño, las observaciones no tienen necesariamente el mismo peso estadístico. Por este motivo, la base de datos incluye factores de expansión o pesos relativos, que permiten que las observaciones seleccionadas representen adecuadamente a la población de referencia.

Cada estudiante participante fue evaluado mediante cuatro instancias: dos cuestionarios y dos pruebas. Los cuestionarios corresponden a un formulario de contexto y un formulario socioemocional, mientras que las evaluaciones de desempeño corresponden a una prueba de matemática y una prueba de lectura.

Para el presente trabajo se descargó la información disponible en el sitio oficial del INEEEd en formato CSV. Se utilizaron dos archivos principales: uno correspondiente a la información de contexto de los estudiantes y otro correspondiente a sus características socioemocionales. Ambos archivos contienen información relacionada con el resultado obtenido en la prueba de matemática, lo que permitió integrar las diferentes dimensiones de información para construir la base analítica utilizada en el estudio.

## 2. Variable objetivo: desempeño en matemática

La variable de resultado utilizada en el análisis corresponde al nivel de desempeño alcanzado por el estudiante en la prueba de matemática.

El INEEd clasifica el desempeño de los estudiantes en seis categorías: B1, Nivel 1, Nivel 2, Nivel 3, Nivel 4 y Nivel 5. Estos niveles describen las capacidades que el estudiante demuestra en términos de la complejidad cognitiva de las tareas que puede resolver, tomando como referencia los programas oficiales de la Administración Nacional de Educación Pública (ANEP).

De forma general, los niveles pueden interpretarse de la siguiente manera:

- B1 y Nivel 1: el estudiante puede resolver tareas matemáticas muy elementales, generalmente rutinarias y con información explícita. Nivel 2: el estudiante puede resolver problemas simples que requieren un procedimiento de un paso o extraer información directa de tablas y gráficos.
- Nivel 3: constituye un nivel de transición hacia la competencia matemática esperada. El estudiante puede resolver problemas que requieren relacionar información o realizar cálculos secuenciales sencillos.
- Niveles 4 y 5: representan una consolidación más profunda de los aprendizajes. Los estudiantes pueden modelizar situaciones de la vida real, resolver problemas no rutinarios, interpretar conceptos algebraicos y fundamentar sus respuestas.

### 0.3.1 Binarización del desempeño

Para el desarrollo de los modelos de aprendizaje supervisado, la variable original de seis categorías fue transformada en una variable binaria. Se definió como desempeño insatisfactorio, codificado como 1, a los estudiantes pertenecientes a las categorías:

B1, Nivel 1, Nivel 2 y Nivel 3.

Por otro lado, se definió como desempeño satisfactorio, codificado como 0, a los estudiantes pertenecientes a:

Nivel 4 y Nivel 5.

Esta clasificación responde a una decisión analítica orientada a la perspectiva de política pública adoptada en este trabajo. Bajo este criterio, alcanzar el Nivel 3 no se considera suficiente para clasificar el desempeño como satisfactorio, ya que representa un nivel de transición hacia la competencia esperada. El desempeño satisfactorio se define, en cambio, como la consolidación de aprendizajes que permita al estudiante enfrentar situaciones matemáticas de mayor complejidad, representadas por los Niveles 4 y 5.

La binarización permite transformar el problema en una tarea de clasificación supervisada, facilitando posteriormente la aplicación e interpretación de distintos modelos de aprendizaje automático.

### 3. Selección de los features

El objetivo del análisis no es únicamente predecir el resultado de la prueba, sino identificar las variables que presentan mayor relevancia para comprender las diferencias observadas en el desempeño matemático.

Por este motivo, se priorizaron los índices contruidos por el INEE, los cuales sintetizan información proveniente de un conjunto amplio de variables categóricas obtenidas mediante los cuestionarios aplicados a los estudiantes.

La utilización de estos índices permite incorporar información previamente estructurada y construida a partir de conocimiento metodológico especializado, evitando reducir el análisis a la evaluación aislada de decenas de respuestas categóricas individuales.

Además de los índices, se incorporaron variables sociodemográficas y educativas consideradas relevantes desde el marco teórico:

- Ascendencia racial.
- Género del estudiante.
- Zona del país: Montevideo o Interior.
- Región del país: Este, Oeste, Norte, Sur y Centro.
- Categoría del centro educativo: Secundaria pública, Secundaria privada y UTU.
- Categoría del grupo: Secundaria pública, Secundaria privada, UTU-CBT y UTU-FPB.

De esta manera, el conjunto de variables predictoras incorpora las diferentes dimensiones planteadas en el marco teórico: socioeconómica, familiar y cultural, escolar e individual.

### 4. Tratamiento de los pesos muestrales y reajuste por participación

Una particularidad importante de los datos utilizados es que las observaciones provienen de una encuesta con diseño muestral estratificado. Por lo tanto, cada estudiante cuenta con un peso que representa la cantidad de estudiantes de la población a la que dicha observación representa.

Sin embargo, no todos los estudiantes incluidos en el padrón cuentan necesariamente con un resultado válido en la prueba de matemática. Dado que los modelos supervisados requieren que la variable objetivo esté observada, eliminar las observaciones sin resultado podría modificar la composición de la población representada y generar un posible sesgo de selección.

Para abordar este problema se realizó un reajuste de los pesos mediante un modelo de propensión a la participación en la prueba.

## 1 1) Reajuste de pesos

En esta parte del flujo se construye el peso final que se utilizará para las observaciones que sí cuentan con resultado de matemática. La idea es corregir el posible sesgo de selección que aparece cuando no todos los estudiantes tienen la misma probabilidad de haber rendido la prueba.

1. Se define una variable de participación:

$$R_i = \begin{cases} 1, & \text{si el estudiante } i \text{ rindió la prueba de matemática} \\ 0, & \text{si no la rindió} \end{cases}$$

Esta variable se calcula observando los NaNs de **Niveles\_MAT**

2. Sobre todo el padrón completo se estima una probabilidad de participación mediante un modelo de propensión.

Para esto se calculan por grupo, las proporciones de estudiantes que efectivamente rindieron la prueba:

$$\hat{p}_i = \frac{R_g}{Total_g}$$

Siendo  $\hat{p}_i$  la probabilidad del estudiante  $i$  de haber realizado la prueba,  $R_g$  la cantidad de estudiantes de un grupo  $g$  que rindieron la prueba, y  $Total_g$  la cantidad de estudiantes que figuran administrativamente como inscriptos en el grupo  $g$ . Para este cálculo se utiliza la variable **GrupoCodigoDes** que es el identificador único de los grupos de estudiantes.

3. Para las observaciones que sí tienen resultado de matemática, el peso original de la encuesta se ajusta dividiendo por esa probabilidad estimada:

$$w_i^{adj} = \frac{w_i^{orig}}{\hat{p}_i}$$

Esto compensa el hecho de que los estudiantes con menor probabilidad de rendir la prueba tienen menos representación en la muestra observada.

4. Para evitar que los pesos se vuelvan excesivamente grandes cuando  $\hat{p}_i$  es muy pequeño, se impone un piso de estabilidad:

$$\hat{p}_i \leftarrow \max(\hat{p}_i, 0.05)$$

5. Finalmente, se normaliza el total de los pesos ajustados para que la suma siga siendo coherente con el total del padrón original:

$$\text{factor de normalización} = \frac{\sum_j w_j^{orig}}{\sum_{k: R_k=1} w_k^{adj}}$$

y por lo tanto:

$$w_i^{final} = \text{factor de normalización} \cdot w_i^{adj}$$

En resumen, el procedimiento busca reponderar las observaciones observadas para que representen mejor a la población total, aún cuando no todos los estudiantes cuentan con resultado de matemática.

## 1.1 EDA

## 1.2 Auditoría de variables

Dimensiones del dataset: 9539 filas × 37 columnas






|                                     | dtype   | nulos | pct_nulos | valores_únicos | moda               | ejemplo            |
|-------------------------------------|---------|-------|-----------|----------------|--------------------|--------------------|
| zona                                | object  | 0     | 0.000000  | 2              | Interior           | Interior           |
| region                              | object  | 0     | 0.000000  | 5              | SUR                | OESTE              |
| departamento_residencia             | float64 | 612   | 6.420000  | 20             | 1.000000           | 5.000000           |
| categoría_centro                    | object  | 0     | 0.000000  | 3              | Secundaria pública | Secundaria pública |
| categoría_grupo                     | object  | 0     | 0.000000  | 4              | Secundaria pública | Secundaria pública |
| alumno_genero                       | object  | 93    | 0.970000  | 3              | M                  | F                  |
| ascendencia                         | float64 | 612   | 6.420000  | 6              | 1.000000           | 1.000000           |
| pais_nacimiento                     | float64 | 612   | 6.420000  | 10             | 1.000000           | 1.000000           |
| edad                                | float64 | 271   | 2.840000  | 16             | 15.000000          | 15.000000          |
| idx_inse_alumno                     | float64 | 633   | 6.640000  | 80             | 39.000000          | 38.000000          |
| idx_esec_alumno                     | float64 | 0     | 0.000000  | 2088           | -0.465260          | -0.436039          |
| idx_esec_centro                     | float64 | 0     | 0.000000  | 339            | -0.572519          | -0.036352          |
| idx_esec_grupo                      | float64 | 0     | 0.000000  | 611            | 0.291839           | 0.078042           |
| idx_sentido_pertenencia             | float64 | 682   | 7.150000  | 661            | 52.058668          | 49.352071          |
| idx_vinculo_entre_estudiantes       | float64 | 652   | 6.840000  | 1112           | 56.841130          | 52.827236          |
| idx_vinculo_estudiantes_adscriptos  | float64 | 660   | 6.920000  | 1200           | 68.457301          | 47.752799          |
| idx_vinculo_estudiantes_docentes    | float64 | 660   | 6.920000  | 1038           | 52.919004          | 50.455867          |
| idx_voz_estudiante                  | float64 | 719   | 7.540000  | 1286           | 47.812056          | 53.745306          |
| idx_actitud_lectura                 | float64 | 642   | 6.730000  | 1287           | 50.992482          | 64.132197          |
| idx_actitud_matematica              | float64 | 642   | 6.730000  | 1261           | 69.693212          | 48.925147          |
| idx_autocontrol                     | float64 | 566   | 5.930000  | 871            | 51.629505          | NaN                |
| idx_autoefcacia_idioma_espanol      | float64 | 548   | 5.740000  | 457            | 49.634164          | NaN                |
| idx_autoefcacia_matematica          | float64 | 546   | 5.720000  | 578            | 66.931399          | NaN                |
| idx_autoregulacion_metacognitiva    | float64 | 545   | 5.710000  | 1834           | 69.637535          | NaN                |
| idx_empatia                         | float64 | 556   | 5.830000  | 762            | 50.546362          | NaN                |
| idx_conductas_externalizantes       | float64 | 566   | 5.930000  | 2357           | 36.697606          | NaN                |
| idx_habilidades_interpersonales     | float64 | 556   | 5.830000  | 8016           | 52.106994          | NaN                |
| idx_habilidades_intrapersonales     | float64 | 565   | 5.920000  | 8122           | 52.762366          | NaN                |
| idx_habilidades_relacionamiento     | float64 | 557   | 5.840000  | 1951           | 52.732579          | NaN                |
| idx_conductas_internalizantes       | float64 | 566   | 5.930000  | 5666           | 31.603074          | NaN                |
| idx_motivacion_aprendizaje          | float64 | 545   | 5.710000  | 8984           | 80.216373          | NaN                |
| idx_motivacion_intrinseca           | float64 | 553   | 5.800000  | 606            | 45.096011          | NaN                |
| idxperseverancia_academica          | float64 | 555   | 5.820000  | 1459           | 50.311376          | NaN                |
| idx_regulacion_emocional            | float64 | 565   | 5.920000  | 1941           | 54.561106          | NaN                |
| idx_valoracion_tarea_idioma_espanol | float64 | 550   | 5.770000  | 555            | 50.561581          | NaN                |
| idx_valoracion_tarea_matematica     | float64 | 549   | 5.760000  | 591            | 47.914845          | NaN                |
| target                              | int64   | 0     | 0.000000  | 2              | 1.000000           | 1                  |

Tabla 1: Auditoría de variables del dataset

## 1.3 Barplots categóricos

Análisis de la tasa de desaprobación según variables categóricas  
n = 9,539




### 1.3.1 Análisis de los barplots categóricos

A partir de los gráficos, se observa que la tasa global de desaprobación en la prueba de Matemática es elevada (88,7%), aunque existen diferencias entre los distintos grupos analizados.

- Zona de residencia: los estudiantes del Interior presentan una tasa de desaprobación superior a la media y mayor que la observada en Montevideo, lo que sugiere una leve brecha territorial en el desempeño.
- Región: se aprecian diferencias moderadas entre regiones. Norte, Este y Oeste exhiben las tasas de desaprobación más altas, mientras que la región Sur presenta la menor proporción de estudiantes desaprobados, ubicándose por debajo de la tasa global.
- Departamento de residencia: existe heterogeneidad entre departamentos. Algunos, como Artigas, muestran tasas de desaprobación cercanas al 97%, mientras que Montevideo y Durazno presentan valores relativamente menores. Sin embargo, en varios departamentos el tamaño muestral es reducido, por lo que esas diferencias deben interpretarse con cautela.
- Género: las diferencias son prácticamente inexistentes. Mujeres y varones presentan tasas de desaprobación muy similares, cercanas a la media, mientras que la categoría “Otro” se ubica levemente por debajo, aunque con un número muy pequeño de casos (n=231).
- Ascendencia: se observan algunas diferencias. Los estudiantes que se identifican con ascendencia asiática o amarilla presentan la mayor tasa de desaprobación, seguidos por quienes reportan ascendencia afro o negra y otra. En contraste, quienes declaran ascendencia blanca muestran la menor tasa de desaprobación del grupo, situándose por debajo de la media global.

## 1.4 Boxplots numéricos

### Análisis de variables cuantitativas vs. Desaprobación / Aprobación (Boxplots)



### 1.4.1 Análisis de los boxplots numéricos

A partir de los boxplots se observan diferencias claras entre los estudiantes que aprueban (0) y quienes desaprueban (1) la prueba de Matemática para algunos de los índices analizados.


- Estatus del nivel socioeconómico del estudiante: los estudiantes que aprueban presentan, en general, un nivel socioeconómico más alto. La mediana del índice es considerablemente superior en el grupo que aprueba, mientras que quienes desaprueban se concentran en

valores más bajos. Esto sugiere una asociación negativa entre el nivel socioeconómico y la probabilidad de desaprobación.

- Índice del nivel cultural y socioeconómico del estudiante: se observa un patrón similar al anterior. Los estudiantes que aprueban presentan valores positivos y una mediana claramente superior, mientras que quienes desaprueban se concentran en valores inferiores. La diferencia entre ambos grupos es marcada, lo que indica que este índice podría ser un importante factor asociado al desempeño en Matemática.
- Índice de actitud hacia la matemática: los estudiantes que aprueban muestran una actitud más favorable hacia la asignatura, reflejada en una mediana sensiblemente mayor. Aunque existe cierto solapamiento entre ambos grupos, la distribución evidencia que una actitud más positiva hacia la Matemática se asocia con una menor probabilidad de desaprobación.
- Índice de vínculo entre estudiantes y docentes: las distribuciones de ambos grupos son muy similares, con medianas prácticamente iguales y una fuerte superposición de los rangos intercuartílicos. Esto sugiere que, de manera aislada, este indicador presenta una capacidad limitada para diferenciar entre estudiantes que aprueban y desaprueban.
- Índice de sentido de pertenencia: también se observan diferencias reducidas entre ambos grupos. Los estudiantes que aprueban presentan una mediana ligeramente superior, aunque la superposición entre las distribuciones es considerable, por lo que el sentido de pertenencia parece tener una asociación más débil con el resultado de la prueba.



## 1.5 Barplots numéricos





## 1.6 Correlaciones lineales



Ranking de correlación de índices socioemocionales vs Target



### 1.6.1 Análisis de correlaciones con la tasa de desaprobación (target)

- Los factores socioeconómicos y educativos (idx\_inse\_alumno e idx\_esec\_alumno) son los que más se asocian (aunque de forma moderada) con la desaprobación: a mejores índices, menor tasa de desaprobación.
- La actitud hacia matemáticas tiene cierta influencia, pero es más débil que los factores estructurales.
- El vínculo con docentes y el sentido de pertenencia tienen una correlación casi nula con la desaprobación, lo que sugiere que, en este contexto, no son factores determinantes para explicar el rendimiento en términos de aprobación/desaprobación.
- No hay correlaciones fuertes (todas están por debajo de 0.4 en valor absoluto), lo que indica que la desaprobación es un fenómeno multifactorial y que estas variables explican solo una parte de su variabilidad.

## 1.7 Entrenamiento de los modelos

### 1.7.1 Categorización de variables

### 1.7.2 Column transformers

### 1.7.3 Definición de modelos y corrida

Entrenando Regresion\_Logistica...

Entrenando Random\_Forest...

Entrenando XGBoost...

### 1.7.4 Resultados de los modelos

--- Comparación de Modelos (ROC-AUC en Validación Cruzada) ---

Modelo: Regresion\_Logistica

Score (ROC-AUC): 0.8814

Hiperparámetros elegidos:

- clasificador\_C: 0.1
- clasificador\_l1\_ratio: 0.0

-----

Modelo: Random\_Forest  
Score (ROC-AUC): 0.8753  
Hiperparámetros elegidos:  
- clasificador\_\_max\_depth: 12  
- clasificador\_\_min\_samples\_leaf: 10  
- clasificador\_\_min\_samples\_split: 20  
- clasificador\_\_n\_estimators: 200

---

Modelo: XGBoost  
Score (ROC-AUC): 0.8832  
Hiperparámetros elegidos:  
- clasificador\_\_learning\_rate: 0.05  
- clasificador\_\_max\_depth: 5  
- clasificador\_\_n\_estimators: 200  
- clasificador\_\_subsample: 0.8

---

### 1.7.5 Cálculo de Feature y Permutation Importance

### 1.7.6 Cálculo de RFECV

Ejecutando RFECV para: Regresion\_Logistica  
- Features seleccionadas: 64  
- Mejor ROC-AUC CV (RFECV): 0.8797

Ejecutando RFECV para: Random\_Forest  
- Features seleccionadas: 75  
- Mejor ROC-AUC CV (RFECV): 0.8775

Ejecutando RFECV para: XGBoost  
- Features seleccionadas: 52  
- Mejor ROC-AUC CV (RFECV): 0.8831

### 1.7.7 Gráficas comparativas

#### 1.7.7.1 Top 10 (Internas, Permutación, RFECV)

=====

TOP VARIABLES SELECCIONADAS POR CADA MODELO (RFECV)

=====

|         | Regresion_Logistica               | Random_Forest                            | XGBoost     |
|---------|-----------------------------------|------------------------------------------|-------------|
| Rank 1  | num__idx_esec_alumno              | num__idx_actitud_matematica              | num__idx_c  |
| Rank 2  | cat__departamento_residencia_2.0  | num__idx_esec_centro                     | num__idx_c  |
| Rank 3  | cat__categoria_grupo_UTU-FPB      | num__idx_autoeficacia_matematica         | num__idx_a  |
| Rank 4  | num__idx_inse_alumno              | num__idx_esec_alumno                     | num__idx_a  |
| Rank 5  | cat__departamento_residencia_16.0 | num__idx_esec_grupo                      | cat__catego |
| Rank 6  | cat__departamento_residencia_5.0  | num__idx_inse_alumno                     | num__idx_c  |
| Rank 7  | num__idx_autoeficacia_matematica  | cat__categoria_grupo_Secundaria privada  | cat__catego |
| Rank 8  | num__idx_actitud_matematica       | num__idx_motivacion_aprendizaje          | cat__catego |
| Rank 9  | num__idx_esec_centro              | cat__categoria_centro_Secundaria privada | cat__edad   |
| Rank 10 | cat__departamento_residencia_19.0 | num__idx_actitud_lectura                 | cat__depart |

## Análisis Integral de Importancia de Variables: Interna vs Permutación vs RFECV

