

Entrega final: Proyecto de mejora en la inversión en educación: ¿qué factores están detrás del desempeño estudiantil en matemática?

Grupo Los Parsimoniosos

Esteban Cardoso, Enrique De Martini, Lucas Barrios

Índice

1. Motivación	2
2. Objetivo	2
3. Marco teórico	2
3.1. Enfoque socioeconómico	2
3.2. Enfoque familiar y cultural	3
3.3. Enfoque escolar	3
3.4. Enfoque individual	3
4. Metodología	3
4.1. Fuente de información y diseño de la encuesta	3
4.2. Variable objetivo: desempeño en matemática	4
4.3. Binarización del desempeño	5
4.4. Selección de los features	5
4.5. Tratamiento de los pesos muestrales y reajuste por participación	7
4.6. Entrenamiento de los modelos	8
4.6.1. Categorización de las variables	8
4.6.2. Selección de los modelos	9
4.6.3. Identificación de las variables más relevantes que gobiernan el fenómeno	10
4.7. Análisis explicativo complementario	10
5. Análisis Exploratorio de los Datos	11
5.1. Auditoria inicial	11
5.2. Barplots categóricos	13
5.3. Boxplots numéricos	15
5.4. Barplots numéricos	17
5.5. Correlaciones lineales	18
6. Resultados	21
6.1. Comparación de Modelos (ROC-AUC en Validación Cruzada)	21
6.2. Features encontradas a partir de los modelos	21
6.2.1. Interpretación de los resultados a la luz de las teorías del desempeño educativo	22
6.2.2. Síntesis de los resultados arrojados por la Importancia de Variables	24
6.2.3. Análisis del HeatMap comparativo	25
6.3. Árbol de decisión	26
7. Conclusiones y recomendaciones finales	27

1. Motivación

El desempeño educativo de los estudiantes es el resultado de un conjunto de factores que interactúan entre sí y que abarcan dimensiones sociales, económicas, familiares, escolares e individuales. En particular, el aprendizaje de la matemática constituye una dimensión relevante del desarrollo educativo, debido a su carácter acumulativo y a su contribución al desarrollo de capacidades analíticas, lógicas y de resolución de problemas.

En la economía del conocimiento, formar recursos humanos que manejen adecuadamente la matemática, ayudará a elevar la capacidad de investigación y desarrollo local y por ende mejorar la competitividad del país. Por eso es relevante investigar los resultados que el país está logrando en el desempeño matemático y ejecutar acciones que mejoren ese desempeño.

Comprender los factores asociados al desempeño matemático permite avanzar más allá de la descripción de los resultados obtenidos por los estudiantes y aproximarse a la identificación de las condiciones que se relacionan con un mejor o peor desempeño. Este conocimiento resulta especialmente relevante para la formulación de políticas educativas, dado que permite identificar dimensiones potencialmente susceptibles de intervención y orientar los recursos hacia aquellos factores que presentan una mayor asociación con los resultados de aprendizaje.

2. Objetivo

El objetivo principal de este proyecto es determinar cuáles son las variables más relevantes que explican el éxito o fracaso en el aprendizaje de la matemática en estudiantes de último año de ciclo básico de educación media en Uruguay. Para lograrlo, se busca trascender la descripción tradicional de los resultados, analizando de manera integral cómo interactúan múltiples dimensiones (socioeconómicas, familiares, escolares e individuales) a partir de los datos de la evaluación Aristas Media 2022 del INEE.

Mediante la aplicación comparativa de modelos de aprendizaje supervisado, el estudio no solo pretende predecir el desempeño, sino identificar los factores de mayor impacto sobre el logro académico. En última instancia, el propósito es generar evidencia empírica que oriente el diseño de políticas públicas educativas y permita optimizar la inversión en el sector, focalizando los recursos en aquellas áreas susceptibles de intervención que presenten una mayor asociación con la mejora del aprendizaje.

3. Marco teórico

El análisis del desempeño educativo se sustenta en diferentes perspectivas teóricas que permiten comprender la influencia de las condiciones en las que se desarrolla el proceso de aprendizaje. Estas perspectivas no deben entenderse como explicaciones excluyentes, sino como dimensiones complementarias que permiten abordar el fenómeno desde distintos niveles.

3.1. Enfoque socioeconómico

El enfoque socioeconómico sostiene que el origen social y las condiciones económicas del hogar condicionan las oportunidades educativas de los estudiantes. Las diferencias en los recursos disponibles pueden afectar tanto las condiciones materiales en las que se desarrolla el aprendizaje como el acceso a bienes y oportunidades educativas.

Desde esta perspectiva, variables como el ingreso del hogar, el nivel educativo de los padres, la ocupación de los adultos responsables, las condiciones de vivienda y las situaciones de pobreza pueden estar asociadas al desempeño académico.

La hipótesis general de este enfoque es que los estudiantes que se desarrollan en contextos con mayores recursos económicos y sociales pueden disponer de mejores condiciones para sostener

sus trayectorias educativas y enfrentar las exigencias del proceso de aprendizaje.

3.2. Enfoque familiar y cultural

El enfoque familiar y cultural pone el énfasis en el entorno inmediato del estudiante y en los recursos culturales y sociales disponibles en su hogar. La familia puede contribuir al aprendizaje mediante la generación de hábitos, expectativas y prácticas que favorecen el desarrollo de competencias educativas.

Entre las variables asociadas a esta perspectiva se encuentran la frecuencia de lectura en el hogar, las expectativas familiares, la participación de los padres en la educación, el capital cultural y el capital social.

Desde este enfoque, el desempeño educativo no depende exclusivamente de los recursos económicos disponibles, sino también de las prácticas familiares, las expectativas respecto de la educación y la exposición del estudiante a actividades y recursos que favorecen el aprendizaje.

3.3. Enfoque escolar

El enfoque escolar centra la atención en las características de las instituciones educativas y en las condiciones en las que se desarrolla el proceso de enseñanza y aprendizaje. Desde esta perspectiva, las diferencias en los resultados educativos pueden estar relacionadas con los recursos y las prácticas de las instituciones a las que concurren los estudiantes.

Entre las principales variables consideradas se encuentran la calidad docente, la infraestructura, los recursos educativos disponibles, el clima escolar, el liderazgo de los equipos de dirección y el tamaño de las clases.

Este enfoque permite incorporar al análisis factores que trascienden las características individuales del estudiante y considerar el papel que desempeña el contexto institucional en la generación de oportunidades de aprendizaje.

3.4. Enfoque individual

El enfoque individual explica las diferencias en el desempeño a partir de características propias de los estudiantes. Estas características pueden estar vinculadas tanto con sus capacidades cognitivas como con aspectos motivacionales, conductuales y socioemocionales.

Entre las variables relevantes se encuentran la inteligencia y las habilidades cognitivas, la motivación, la autoeficacia, la salud física y mental, los hábitos de estudio y la asistencia a clases.

Desde esta perspectiva, los estudiantes pueden presentar diferentes niveles de desempeño aun cuando compartan un contexto socioeconómico o educativo similar, debido a diferencias en sus habilidades, actitudes, hábitos y experiencias individuales.

4. Metodología

4.1. Fuente de información y diseño de la encuesta

En el desarrollo de la investigación se utilizó la información correspondiente a [Aristas Media 2022](#) (Ficha técnica: [1]), evaluación realizada por el Instituto Nacional de Evaluación Educativa (INEED) a estudiantes que cursaban el último año del ciclo básico de educación media en Uruguay.

La encuesta comprende estudiantes pertenecientes a centros educativos de carácter público y privado de todo el país, incluyendo instituciones de educación secundaria y centros de la UTU. El diseño de la muestra es de carácter estratificado, lo que implica que la población estudiantil fue dividida previamente en grupos o estratos definidos a partir de determinadas características

relevantes para el diseño muestral. Posteriormente, se seleccionaron unidades dentro de cada estrato, procurando garantizar la representación de los distintos contextos educativos y geográficos de la población objetivo.

Como consecuencia de este diseño, las observaciones no tienen necesariamente el mismo peso estadístico. Por este motivo, la base de datos incluye factores de expansión o pesos relativos, que permiten que las observaciones seleccionadas representen adecuadamente a la población de referencia.

Cada estudiante participante fue evaluado mediante cuatro instancias: dos cuestionarios y dos pruebas. Los cuestionarios corresponden a un formulario de contexto y un formulario socioemocional, mientras que las evaluaciones de desempeño corresponden a una prueba de matemática y una prueba de lectura.

Para el presente trabajo se descargó la información disponible en el sitio oficial del INEEd en formato CSV. Se utilizaron dos archivos principales: uno correspondiente a la información de contexto de los estudiantes y otro correspondiente a sus características socioemocionales. Ambos archivos contienen información relacionada con el resultado obtenido en la prueba de matemática, lo que permitió integrar las diferentes dimensiones de información para construir la base analítica utilizada en el estudio.

Para la construcción del dataset final, se realizó un merge entre los dos archivos CSV mediante el identificador único del estudiante llamado **AlumnoCodigoDes** y con el argumento `how='outer'`.

```
df_merged = df_cxto.merge(df_socio[cols_socio_nuevas],
                          on="AlumnoCodigoDes", how="outer")
```

Pasando de dos datasets con 484 (`df_cxto`) y 324 (`df_socio`) columnas a uno con 621 sin repetidas.

4.2. Variable objetivo: desempeño en matemática

La variable de resultado utilizada en el análisis corresponde al nivel de desempeño alcanzado por el estudiante en la prueba de matemática.

El INEEd clasifica el desempeño de los estudiantes en seis categorías: B1, Nivel 1, Nivel 2, Nivel 3, Nivel 4 y Nivel 5. Estos niveles describen las capacidades que el estudiante demuestra en términos de la complejidad cognitiva de las tareas que puede resolver, tomando como referencia los programas oficiales de la Administración Nacional de Educación Pública (ANEP).

De forma general, los niveles pueden interpretarse de la siguiente manera:

- **B1 y Nivel 1:** el estudiante puede resolver tareas matemáticas muy elementales, generalmente rutinarias y con información explícita.
- **Nivel 2:** el estudiante puede resolver problemas simple que requieren un procedimiento de un paso o extraer información directa de tablas y gráficos.
- **Nivel 3:** constituye un nivel de transición hacia la competencia matemática esperada. El estudiante puede resolver problemas que requieren relacionar información o realizar cálculos secuenciales sencillos.
- **Niveles 4 y 5:** representan una consolidación más profunda de los aprendizajes. Los estudiantes pueden modelizar situaciones de la vida real, resolver problemas no rutinarios, interpretar conceptos algebraicos y fundamentar sus respuestas.

4.3. Binarización del desempeño

Para el desarrollo de los modelos de aprendizaje supervisado, la variable original de seis categorías fue transformada en una variable binaria. Se definió como desempeño insatisfactorio, codificado como 1, a los estudiantes pertenecientes a las categorías: B1, Nivel 1, Nivel 2 y Nivel 3.

Por otro lado, se definió como desempeño satisfactorio, codificado como 0, a los estudiantes pertenecientes a: Nivel 4 y Nivel 5.

Esta clasificación responde a una decisión analítica orientada a la perspectiva de política pública adoptada en este trabajo. Bajo este criterio, alcanzar el Nivel 3 no se considera suficiente para clasificar el desempeño como satisfactorio, ya que representa un nivel de transición hacia la competencia esperada. El desempeño satisfactorio se define, en cambio, como la consolidación de aprendizajes que permita al estudiante enfrentar situaciones matemáticas de mayor complejidad, representadas por los Niveles 4 y 5.

La binarización permite facilitar la aplicación e interpretación posterior de los resultados de los distintos modelos de aprendizaje automático.

4.4. Selección de los features

El objetivo del análisis no es predecir el resultado de la prueba, sino identificar las variables que presentan mayor relevancia para comprender las diferencias observadas en el desempeño matemático.

Por este motivo, se priorizaron los índices construidos por el INEE, los cuales sintetizan información proveniente de un conjunto amplio de variables categóricas obtenidas mediante los cuestionarios aplicados a los estudiantes.

La utilización de estos índices permite incorporar información previamente estructurada y construida a partir de conocimiento metodológico especializado, evitando reducir el análisis a la evaluación aislada de decenas de respuestas categóricas individuales.

Además de los índices, se incorporaron variables sociodemográficas y educativas consideradas relevantes desde el marco teórico:

- Ascendencia racial.
- Género del estudiante.
- Zona del país: Montevideo o Interior.
- Región del país: Este, Oeste, Norte, Sur y Centro.
- Categoría del centro educativo: Secundaria pública, Secundaria privada y UTU.
- Categoría del grupo: Secundaria pública, Secundaria privada, UTU-CBT y UTU-FPB.

De esta manera, el conjunto de variables predictoras incorpora las diferentes dimensiones planteadas en el marco teórico: socioeconómica, familiar y cultural, escolar e individual.

En la tabla 1 se desglosan las variables a utilizar así como el cambio de nombre que se realiza para una mejor interpretación de los resultados posteriores.

Tabla 1: Diccionario para mapear las variables predictoras

Variable Original (INEEd)	Variable Renombrada
DATASET: CXTO (Datos de Contexto y Diseño Muestral)	
<i>Variables Demográficas y Geográficas</i>	
MdeoInt	zona
regiones	region
EF46m	departamento_residencia
categoria_centro	categoria_centro
categoria_grupo	categoria_grupo
AlumnoGenero	alumno_genero
EF2d	ascendencia
EF2b	pais_nacimiento
EDAD	edad
<i>Índices de Estatus Económico y Social</i>	
INSE	idx_inse_alumno
ESCS_Alumno	idx_esec_alumno
ESCS_Centro	idx_esec_centro
ESCS_Grupo	idx_esec_grupo
DATASET: SOCIO (Cuestionario Socioemocional)	
<i>Índices de Contexto y Actitudes</i>	
ESTSENTPER_E_ESC50	idx_sentido_pertenencia
VINCENTREEST_E_ESC50	idx_vinculo_entre_estudiantes
VINESTADS_E_ESC50	idx_vinculo_estudiantes_adscriptos
VINESTPROF_E_ESC50	idx_vinculo_estudiantes_docentes
VOZESTU_E_ESC50	idx_voz_estudiante
ACTITUDLEC_E_ESC50	idx_actitud_lectura
ACTITUDMAT_E_ESC50	idx_actitud_matematica
<i>Índices de Habilidades Socioemocionales y Cognitivas</i>	
AUTOCON_E_ESC50	idx_autocontrol
AUTOEIDE_E_ESC50	idx_autoeficacia_idioma_espanol
AUTOEMAT_E_ESC50	idx_autoeficacia_matematica
AUTOMETA_E_ESC50	idx_autoregulacion_metacognitiva
EMPATIA_E_ESC50	idx_empatia
EXTERNALIZ_E_ESC50	idx_conductas_externalizantes
HABINTER_E_ESC50	idx_habilidades_interpersonales
HABINTRA_E_ESC50	idx_habilidades_intrapersonales
HABRELAC_E_ESC50	idx_habilidades_relacionamiento
INTERNALIZ_E_ESC50	idx_conductas_internalizantes
MOTAUTREGA_E_ESC50	idx_motivacion_aprendizaje
MOTINT_E_ESC50	idx_motivacion_intrinseca
PERSAC_E_ESC50	idx_perseverancia_academica
REGEMO_E_ESC50	idx_regulacion_emocional
VALTIDE_E_ESC50	idx_valoracion_tarea_idioma_espanol
VALTMAT_E_ESC50	idx_valoracion_tarea_matematica

4.5. Tratamiento de los pesos muestrales y reajuste por participación

Una particularidad importante de los datos utilizados es que las observaciones provienen de una encuesta con diseño muestral estratificado. Por lo tanto, cada estudiante cuenta con un peso que representa la cantidad de estudiantes de la población a la que dicha observación representa.

Sin embargo, no todos los estudiantes incluidos en el padrón cuentan necesariamente con un resultado válido en la prueba de matemática. Dado que los modelos supervisados requieren que la variable objetivo esté observada, eliminar las observaciones sin resultado podría modificar la composición de la población representada y generar un posible sesgo de selección.

Para abordar este problema se realizó un reajuste de los pesos mediante un modelo de propensión a la participación en la prueba.

1. Se define una variable de participación:

$$R_i = \begin{cases} 1, & \text{si el estudiante } i \text{ rindió la prueba de matemática} \\ 0, & \text{si no la rindió} \end{cases}$$

Esta variable se calcula observando los NaNs de **Niveles_MAT**.

2. Sobre todo el padrón completo se estima una probabilidad de participación mediante un modelo de propensión. Para esto se calculan por grupo, las proporciones de estudiantes que efectivamente rindieron la prueba:

$$\hat{p}_i = \frac{R_g}{Total_g}$$

Siendo $\hat{p}_i$ la probabilidad del estudiante i de haber realizado la prueba, R_g la cantidad de estudiantes de un grupo g que rindieron la prueba, y $Total_g$ la cantidad de estudiantes que figuran administrativamente como inscriptos en el grupo g . Para este cálculo se utiliza la variable **GrupoCodigoDes** que es el identificador único de los grupos de estudiantes.

3. Para las observaciones que sí tienen resultado de matemática, el peso original de la encuesta se ajusta dividiendo por esa probabilidad estimada:

$$w_i^{adj} = \frac{w_i^{orig}}{\hat{p}_i}$$

Esto compensa el hecho de que los estudiantes con menor probabilidad de rendir la prueba tienen menos representación en la muestra observada.

4. Para evitar que los pesos se vuelvan excesivamente grandes cuando $\hat{p}_i$ es muy pequeño, se impone un piso de estabilidad:

$$\hat{p}_i = \max(\hat{p}_i, 0,01)$$

5. Finalmente, se normaliza el total de los pesos ajustados para que la suma siga siendo coherente con el total del padrón original:

$$\text{factor de normalización} = \frac{\sum_j w_j^{orig}}{\sum_{k:R_k=1} w_k^{adj}}$$

y por lo tanto:

$$w_i^{final} = \text{factor de normalización} \cdot w_i^{adj}$$

En resumen, el procedimiento busca reponderar las observaciones observadas para que representen mejor a la población total, aun cuando no todos los estudiantes cuentan con resultado de matemática.

4.6. Entrenamiento de los modelos

4.6.1. Categorización de las variables

Antes de realizar el entrenamiento de los modelos se clasificaron las variables predictoras según su naturaleza. Se definió explícitamente un conjunto de variables categóricas:

```
columnas_categoricas = [  
    "zona",  
    "region",  
    "departamento_residencia",  
    "categoria_centro",  
    "categoria_grupo",  
    "alumno_genero",  
    "ascendencia",  
    "pais_nacimiento",  
    "edad"  
]
```

Estas variables corresponden principalmente a características demográficas, geográficas y educativas de los estudiantes. En particular:

- **Zona:** identifica si el estudiante reside en Montevideo o en el Interior del país.
- **Región:** identifica la región geográfica de residencia del estudiante.
- **Departamento de residencia:** identifica el departamento en el que reside el estudiante.
- **Categoría del centro:** identifica el tipo de institución educativa a la que asiste el estudiante.
- **Categoría del grupo:** identifica el tipo de grupo educativo al que pertenece el estudiante.
- **Género del alumno:** corresponde a la categoría de género declarada para el estudiante.
- **Ascendencia:** identifica la categoría de ascendencia racial declarada por el estudiante.
- **País de nacimiento:** identifica el país de nacimiento del estudiante.
- **Edad:** representa la categoría de edad del estudiante.

Todas las demás variables incluidas en el conjunto de predictores fueron consideradas numéricas para efectos del procesamiento.

Preprocesamiento mediante ColumnTransformer

Debido a que las variables presentan diferentes tipos y escalas, se implementó un proceso de preprocesamiento mediante un ColumnTransformer, permitiendo aplicar transformaciones diferenciadas según la naturaleza de cada variable.

Para las variables categóricas se utilizó un pipeline compuesto por dos etapas:

```
transformador_cat = Pipeline(steps=[  
    ("imputer", SimpleImputer(strategy="most_frequent")),  
    ("onehot", OneHotEncoder(handle_unknown="ignore", sparse_output=True)),  
)
```


En primer lugar, los valores faltantes fueron imputados utilizando la moda de cada variable. La moda corresponde a la categoría que presenta la mayor frecuencia dentro de la variable. De esta forma, cuando un estudiante presenta un valor nulo en una variable categórica, este es reemplazado por la categoría más frecuente observada.

La utilización de la moda permite conservar todas las observaciones disponibles para el entrenamiento, evitando eliminar estudiantes por presentar información faltante en alguna de las variables predictoras. Además, al tratarse de variables categóricas, la imputación mediante la categoría más frecuente resulta apropiada para mantener el tipo de información original.

Posteriormente, las variables categóricas fueron transformadas mediante One-Hot Encoding, convirtiendo cada categoría en una variable binaria. Se utilizó además `handle_unknown=ignore` para evitar problemas cuando durante alguna etapa del procesamiento aparecieran categorías que no hubieran sido observadas durante el ajuste del transformador.

Para las variables numéricas se decidió aplicar una imputación por el método de vecinos más cercanos (KNN) y un escalado con `StandardScaler`.

```
transformador_num = Pipeline(steps=[
    ("imputer", KNNImputer(n_neighbors=5, weights="distance")),
    ("scaler", StandardScaler()),
])
```

El preprocesamiento completo se incorporó dentro de un Pipeline junto con cada modelo. De esta manera, las transformaciones forman parte del proceso de entrenamiento y se evita realizar transformaciones por fuera del flujo del modelo. En el código utilizado, el `ColumnTransformer` integra el tratamiento de variables numéricas y categóricas antes de aplicar el clasificador.

```
preprocesador = ColumnTransformer(transformers=[
    ("num", transformador_num, columnas_numericas),
    ("cat", transformador_cat, columnas_categoricas),
])
```

4.6.2. Selección de los modelos

Para identificar las variables más relevantes para el desempeño en matemática se seleccionaron tres modelos de aprendizaje supervisado: Regresión Logística, Random Forest y XGBoost. La selección buscó combinar un modelo de menor complejidad e interpretación directa con modelos capaces de representar relaciones más complejas y no lineales.

Regresión Logística: modelo de referencia e interpretable

En primer lugar, se seleccionó la Regresión Logística como modelo de referencia debido a su relativa simplicidad y facilidad de interpretación. Al tratarse de un modelo lineal para clasificación binaria, permite establecer una primera aproximación a la relación entre las variables predictoras y la probabilidad de pertenecer a cada categoría de desempeño.

Su principal ventaja en este contexto es la interpretabilidad de sus coeficientes, ya que permite analizar la dirección y magnitud de la asociación entre las variables y el resultado modelado. Esto resulta particularmente relevante considerando que el objetivo del trabajo no es exclusivamente predictivo, sino que busca identificar y analizar las variables asociadas al desempeño matemático.

Por este motivo, la Regresión Logística constituye un punto de referencia frente a los modelos de mayor complejidad utilizados posteriormente.

Random Forest: mayor capacidad de modelización

En segundo lugar se seleccionó Random Forest, un método basado en un conjunto de árboles de decisión. A diferencia de la Regresión Logística, permite capturar relaciones no lineales entre

las variables y el desempeño, así como interacciones entre predictores que no necesariamente pueden ser representadas mediante una relación lineal.

Random Forest mantiene, al mismo tiempo, un nivel de interpretabilidad superior al de otros modelos de aprendizaje automático más complejos. La estructura basada en árboles permite obtener medidas de importancia de variables y analizar de manera relativamente sencilla qué predictores tienen mayor participación en las decisiones del modelo.

Por estas características, Random Forest funciona como un punto intermedio entre el modelo lineal de referencia y un algoritmo de mayor complejidad como XGBoost.

XGBoost: modelo de mayor complejidad

Finalmente, se seleccionó XGBoost, un algoritmo basado en boosting de árboles de decisión. Este modelo permite representar relaciones no lineales e interacciones complejas entre las variables y construir progresivamente un conjunto de árboles orientado a mejorar el desempeño del modelo.

Su inclusión permite evaluar si aparecen patrones relevantes que no son capturados por la Regresión Logística y que pueden presentar una estructura más compleja que la modelada por Random Forest.

De esta manera, la utilización conjunta de los tres modelos permite comparar diferentes niveles de complejidad:

Regresión Logística $\rightarrow$ Random Forest $\rightarrow$ XGBoost

La comparación resulta especialmente útil para el objetivo del trabajo, ya que permite identificar variables que mantienen su relevancia independientemente del algoritmo utilizado y distinguirlas de aquellas cuya importancia depende de una determinada estructura de modelización.

Los tres modelos fueron implementados dentro de pipelines que incorporan el preprocesamiento y posteriormente optimizados mediante GridSearchCV, utilizando ROC-AUC como métrica de selección y validación cruzada estratificada de cinco particiones.

4.6.3. Identificación de las variables más relevantes que gobiernan el fenómeno

Con el propósito de identificar de manera robusta cuáles son los factores que gobiernan el desempeño en matemática, no se dependió de una única métrica, sino que para cada uno de los modelos entrenados se aplicaron tres herramientas distintas de selección de características (*feature selection*): Importancia Interna (*Feature Importance* o coeficientes), Importancia por Permutación (*Permutation Importance*) y Eliminación Recursiva de Características con Validación Cruzada (RFECV).

Cada una de estas técnicas aporta una perspectiva diferente sobre la relevancia de los datos. Mientras que la importancia interna refleja la estructura matemática propia de cada algoritmo, la importancia por permutación evalúa empíricamente cuánto se degrada el rendimiento del modelo al alterar la información de una variable específica. Por su parte, RFECV permite identificar el subconjunto óptimo de predictores, eliminando iterativamente las variables menos relevantes.

A partir de los resultados obtenidos, se determinaron las variables más significativas del fenómeno. Para sintetizar esta información de manera clara, se desarrolló un *heatmap* comparativo que integra las combinaciones de todos los modelos y herramientas de selección aplicadas. Para lograrlo, los valores de cada columna fueron normalizados y posteriormente promediados, creando así un ranking global que ordena las variables de mayor a menor importancia. Este enfoque de consenso permite mitigar los sesgos particulares de cada algoritmo y obtener una conclusión más estable.

4.7. Análisis explicativo complementario

Finalmente, y en línea con el objetivo de generar evidencia accionable, se construyó un modelo adicional de Árbol de Decisión de baja complejidad. El propósito de este árbol no es

maximizar el poder predictivo, sino priorizar el análisis explicativo. Al mantener una profundidad reducida, permite traducir los patrones complejos encontrados por los otros modelos en reglas de decisión visuales, gráficas y muy sencillas de interpretar, ofreciendo una herramienta directa y transparente para los tomadores de decisión en materia de política pública educativa.

5. Análisis Exploratorio de los Datos

Con el fin de obtener una primera aproximación al dataset se realizó un análisis exploratorio luego de un preprocesamiento básico de selección de variables relevantes en función del marco teórico y metodología elegidos.

Este preprocesamiento también incluye la conversión de algunas columnas que eran leídas como objetos pero que en su naturaleza eran floats, debido que el corte a decimales de los números estaban codificados con una coma en vez de un punto y python los leía como objetos. También se realiza el cambio de los valores 98 y 99 de algunas columnas en las cuales esos valores codifican respuestas de no sabe/no contesta respectivamente, para pasarlos a NaN y que en el procesamiento de los datos sean imputadas con el ColumnTransformer como cualquier dato faltante.

5.1. Auditoria inicial

En la tabla 2 se visualizan las principales características del dataset luego de haber pasado por el preprocesamiento inicial mencionado.

Finalmente se eliminan las filas que tengan valores nulos (NaN) en el target, que corresponden a los estudiantes que no asistieron a la evaluación de matemática, pasando de 11546 filas a 9539.

Tabla 2: Auditoría de variables del dataset preprocesado

Variable	Tipo	Nulos	% Nulos	Valores Únicos	Moda	Ejemplo
zona	object	0	0.00 %	2	Interior	Interior
region	object	0	0.00 %	5	SUR	CENTRO
departamento_residencia	float64	612	6.42 %	20	1	6
categoria_centro	object	0	0.00 %	3	Secundaria pública	Secundaria pública
categoria_grupo	object	0	0.00 %	4	Secundaria pública	Secundaria pública
alumno_genero	object	93	0.97 %	3	M	M
ascendencia	float64	612	6.42 %	6	1	2
pais_nacimiento	float64	612	6.42 %	10	1	1
edad	float64	271	2.84 %	16	15	16
idx_inse_alumno	float64	633	6.64 %	80	39	35
idx_esec_alumno	float64	0	0.00 %	2088	-0.465	-0.501
idx_esec_centro	float64	0	0.00 %	339	-0.573	-0.005
idx_esec_grupo	float64	0	0.00 %	611	0.292	0.043
idx_sentido_pertenencia	float64	682	7.15 %	661	52.059	52.059
idx_vinculo_entre_estudiantes	float64	652	6.84 %	1112	56.841	56.339
idx_vinculo_estudiantes_adscriptos	float64	660	6.92 %	1200	68.457	50.031
idx_vinculo_estudiantes_docentes	float64	660	6.92 %	1038	52.919	52.919
idx_voz_estudiante	float64	719	7.54 %	1286	47.812	55.200
idx_actitud_lectura	float64	642	6.73 %	1287	50.992	36.705
idx_actitud_matematica	float64	642	6.73 %	1261	69.693	54.450
idx_autocontrol	float64	566	5.93 %	871	51.630	45.770
idx_autoeficacia_idioma_espanol	float64	548	5.74 %	457	49.634	43.823
idx_autoeficacia_matematica	float64	546	5.72 %	578	66.931	46.983
idx_autoregulacion_metacognitiva	float64	545	5.71 %	1834	69.638	47.378
idx_empatia	float64	556	5.83 %	762	50.546	50.546
idx_conductas_externalizantes	float64	566	5.93 %	2357	36.698	55.835
idx_habilidades_interpersonales	float64	556	5.83 %	8016	52.107	52.107
idx_habilidades_intrapersonales	float64	565	5.92 %	8122	52.762	31.300
idx_habilidades_relacionamiento	float64	557	5.84 %	1951	52.733	52.733
idx_conductas_internalizantes	float64	566	5.93 %	5666	31.603	57.664
idx_motivacion_aprendizaje	float64	545	5.71 %	8984	80.216	45.399
idx_motivacion_intrinseca	float64	553	5.80 %	606	45.096	49.068
idx_perseverancia_academica	float64	555	5.82 %	1459	50.311	48.680
idx_regulacion_emocional	float64	565	5.92 %	1941	54.561	30.817
idx_valoracion_tarea_idioma_espanol	float64	550	5.77 %	555	50.562	50.562
idx_valoracion_tarea_matematica	float64	549	5.76 %	591	47.915	40.484
target	int64	0	0.00 %	2	1	1

5.2. Barplots categóricos




Figura 1: Desaprobación por Zona, Región, Departamento, Género y Ascendencia

A partir de los gráficos, se observa que la tasa global de desaprobación en la prueba de Matemática es elevada (88,7 %), aunque existen diferencias entre los distintos grupos analizados.

- **Zona de residencia:** los estudiantes del Interior presentan una tasa de desaprobación superior a la media y mayor que la observada en Montevideo, lo que sugiere una leve brecha territorial en el desempeño.
- **Región:** se aprecian diferencias moderadas entre regiones. Norte, Este y Oeste exhiben las tasas de desaprobación más altas, mientras que la región Sur presenta la menor proporción de estudiantes desaprobados, ubicándose por debajo de la tasa global.
- **Departamento de residencia:** existe heterogeneidad entre departamentos. Algunos, como Artigas, muestran tasas de desaprobación cercanas al 97 %, mientras que Montevideo y Durazno presentan valores relativamente menores. Sin embargo, en varios departamentos el tamaño muestral es reducido, por lo que esas diferencias deben interpretarse con cautela.
- **Género:** las diferencias son prácticamente inexistentes. Mujeres y varones presentan tasas de desaprobación muy similares, cercanas a la media, mientras que la categoría “Otro” se ubica levemente por debajo, aunque con un número muy pequeño de casos ($n = 231$).
- **Ascendencia:** se observan algunas diferencias. Los estudiantes que se identifican con ascendencia asiática o amarilla presentan la mayor tasa de desaprobación, seguidos por quienes reportan ascendencia afro o negra y otra. En contraste, quienes declaran ascendencia blanca muestran la menor tasa de desaprobación del grupo, situándose por debajo de la media global.

5.3. Boxplots numéricos




Figura 2: Análisis de variables cuantitativas vs. Insatisfactorio / Satisfactorio

A partir de los boxplots se observan diferencias claras entre los estudiantes que aprueban (0) y quienes desaprueban (1) la prueba de Matemática para algunos de los índices analizados.

- **Estatus del nivel socioeconómico del estudiante:** los estudiantes que aprueban presentan, en general, un nivel socioeconómico más alto. La mediana del índice es considerablemente superior en el grupo que aprueba, mientras que quienes desaprueban se concentran en valores más bajos. Esto sugiere una asociación negativa entre el nivel socioeconómico y la probabilidad de desaprobación.
- **Índice del nivel cultural y socioeconómico del estudiante/centro/grupo:** se observa un patrón similar al anterior. Los estudiantes que aprueban presentan valores positivos y una mediana claramente superior, mientras que quienes desaprueban se concentran en valores inferiores. La diferencia entre ambos grupos es marcada, lo que indica que este índice podría ser un importante factor asociado al desempeño en Matemática.
- **Índice de actitud/autoeficacia relacionada con la matemática:** Ambos índices fueron contruidos a partir de preguntas con respuesta categórica desde “Muy en desacuerdo”

hasta “Muy de acuerdo”.

- Índice de actitud matemática: Se enfoca en preguntas de carácter negativo hacia la matemática.
- Índice de autoeficacia matemática: Se enfoca en preguntas de carácter positivo hacia la matemática.

Los estudiantes que aprueban muestran una actitud más favorable hacia la asignatura, reflejada en una mediana sensiblemente mayor. Aunque existe cierto solapamiento entre ambos grupos, la distribución evidencia que una actitud más positiva hacia la Matemática se asocia con una menor probabilidad de desaprobación.

- **Índice de vínculo entre estudiantes y docentes:** las distribuciones de ambos grupos son muy similares, con medianas prácticamente iguales y una fuerte superposición de los rangos intercuartílicos. Esto sugiere que, de manera aislada, este indicador presenta una capacidad limitada para diferenciar entre estudiantes que aprueban y desaprueban.
- **Índice de sentido de pertenencia:** también se observan diferencias reducidas entre ambos grupos. Los estudiantes que aprueban presentan una mediana ligeramente superior, aunque la superposición entre las distribuciones es considerable, por lo que el sentido de pertenencia parece tener una asociación más débil con el resultado de la prueba.

5.4. Barplots numéricos

Complementando el análisis de los boxplots se realiza una discretización por bins de las mismas variables numéricas.




Figura 3: Tasa de desaprobación por Rangos de índices

5.5. Correlaciones lineales

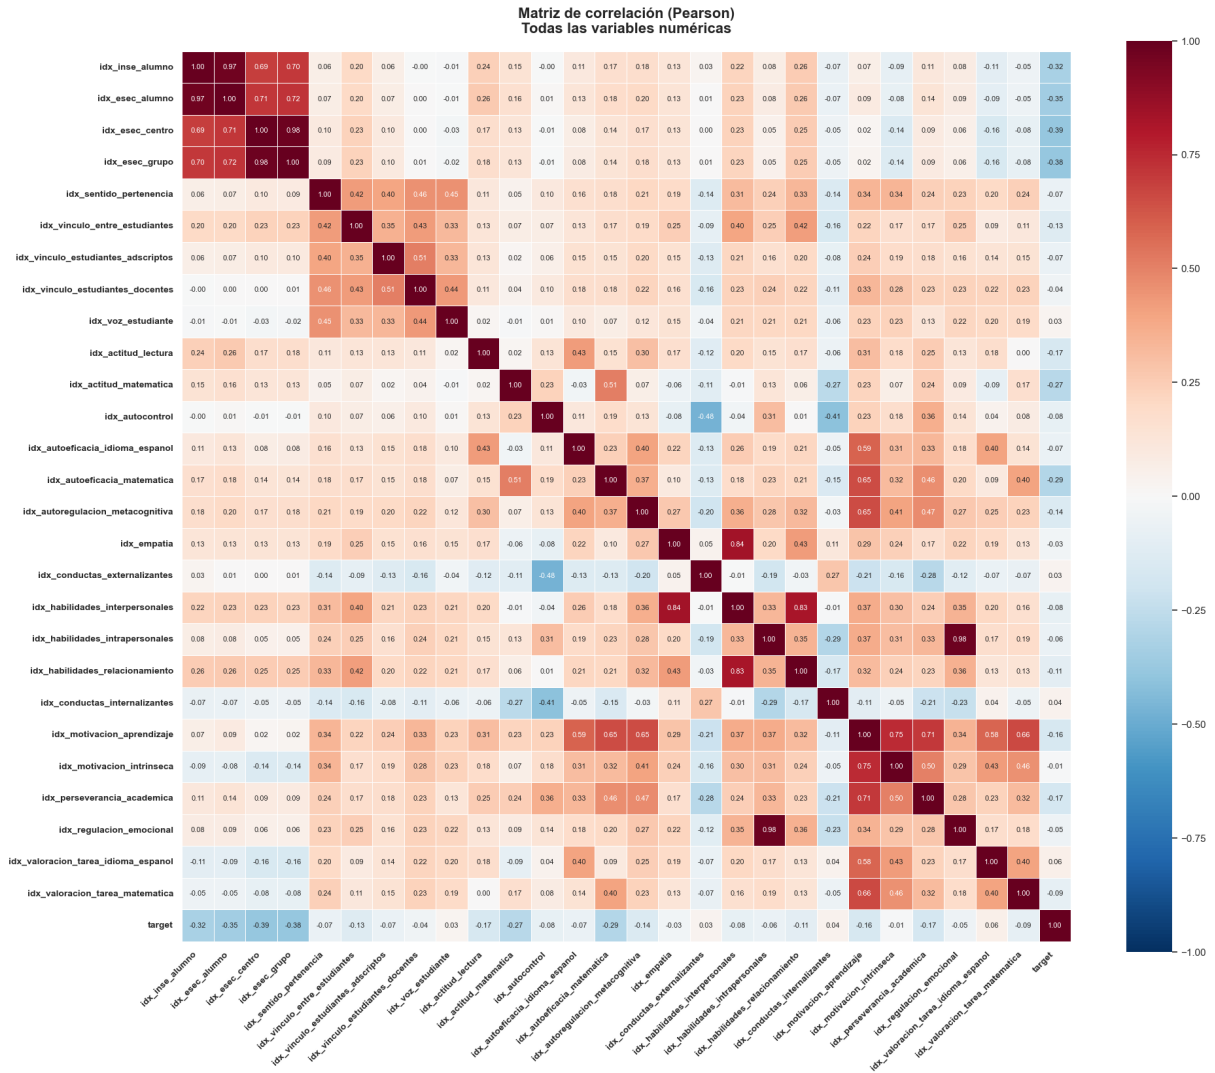


Figura 4: Matriz de correlación (Pearson) de todas las variables numéricas

La matriz de correlaciones presentada permite identificar la existencia de relaciones lineales importantes entre algunas de las variables predictoras. Este aspecto resulta relevante para la etapa posterior de modelización, dado que determinadas variables utilizadas en el análisis representan dimensiones relacionadas o parcialmente superpuestas del fenómeno educativo.

Un ejemplo particularmente relevante corresponde a los índices **esec** e **inse**. Estos presentan una correlación elevada debido a que las dimensiones que representan se encuentran conceptualmente relacionadas, al punto de que una de ellas integra información asociada a la otra. Por este motivo, la elevada correlación observada entre ambas variables no constituye un resultado inesperado, sino que responde a la propia construcción de los índices.

La existencia de estas relaciones entre variables debe ser considerada al momento de interpretar los resultados de los modelos. En particular, una elevada correlación entre predictores puede dificultar la atribución de un efecto individual a una variable determinada, dado que parte de la información que contiene puede ser compartida con otras variables del conjunto de predictores.

No obstante, la presencia de multicolinealidad no implica necesariamente que las variables deban ser eliminadas del análisis. El desempeño educativo constituye un fenómeno de naturaleza **multicausal**, en el que intervienen simultáneamente dimensiones socioeconómicas, individuales, familiares y escolares. Por lo tanto, conservar variables que representan dimensiones conceptual-

mente relevantes permite mantener una representación más completa del fenómeno estudiado, aun cuando algunas de ellas presenten asociaciones entre sí.

Esta consideración resulta especialmente importante para la interpretación posterior de la importancia de las variables. En lugar de interpretar cada predictor de manera completamente aislada, los resultados deben analizarse teniendo presente que algunas variables contienen información parcialmente compartida. En consecuencia, la importancia asignada por un modelo a una variable determinada puede estar relacionada con la presencia de otros predictores que representan dimensiones similares del fenómeno.

Por este motivo, el análisis de correlaciones realizado durante el EDA se utiliza como una instancia de diagnóstico que permite conocer la estructura de las relaciones entre los predictores y tener presente la existencia de multicolinealidad durante las etapas posteriores de modelización y selección de variables.




Figura 5: Ranking de correlación de índices socioemocionales vs Target

Análisis de correlaciones con la tasa de desaprobación (target):

- Los factores socioeconómicos y educativos (idx_inse_alumno e idx_esec_alumno) son los que más se asocian (aunque de forma moderada) con la desaprobación: a mejores índices, menor tasa de desaprobación.
- La actitud hacia matemáticas tiene cierta influencia, pero es más débil que los factores estructurales.
- El vínculo con docentes y el sentido de pertenencia tienen una correlación casi nula con

la desaprobación, lo que sugiere que, en este contexto, no son factores determinantes para explicar el rendimiento en términos de aprobación/desaprobación.

- No hay correlaciones fuertes (todas están por debajo de 0.4 en valor absoluto), lo que indica que la desaprobación es un fenómeno multifactorial y que estas variables explican solo una parte de su variabilidad.

6. Resultados

6.1. Comparación de Modelos (ROC-AUC en Validación Cruzada)

- **Modelo: Regresión Logística**
Score (ROC-AUC): 0.8814
Hiperparámetros elegidos:
 - `clasificador__C`: 0.1
 - `clasificador__l1_ratio`: 0.0
- **Modelo: Random Forest**
Score (ROC-AUC): 0.8747
Hiperparámetros elegidos:
 - `clasificador__max_depth`: 12
 - `clasificador__min_samples_leaf`: 10
 - `clasificador__min_samples_split`: 20
 - `clasificador__n_estimators`: 200
- **Modelo: XGBoost**
Score (ROC-AUC): 0.8840
Hiperparámetros elegidos:
 - `clasificador__learning_rate`: 0.1
 - `clasificador__max_depth`: 3
 - `clasificador__n_estimators`: 200
 - `clasificador__subsample`: 0.8

6.2. Features encontradas a partir de los modelos

Los resultados obtenidos a partir de los modelos de Regresión Logística, Random Forest y XGBoost permiten analizar el desempeño en matemática desde las principales teorías explicativas del rendimiento educativo. La comparación entre distintos algoritmos y técnicas de selección de variables muestra que el fenómeno es multidimensional y que intervienen simultáneamente factores socioeconómicos, individuales y escolares.

Análisis Integral de Importancia de Variables: Interna vs Permutación vs RFECV




Figura 6: Análisis de features (Barplots)

6.2.1. Interpretación de los resultados a la luz de las teorías del desempeño educativo

■ Enfoque socioeconómico

La evidencia más consistente surge del enfoque socioeconómico. Los índices asociados al contexto socioeconómico del estudiante, particularmente `num_idx_esec_alumno` y `num_idx_inse_alumno`, aparecen de forma reiterada entre las variables más importantes en los distintos modelos y metodologías de selección. En la Regresión Logística estas variables ocupan posiciones destacadas tanto en la importancia interna como en los resultados de RFECV, mientras que en Random Forest y XGBoost mantienen niveles elevados de

importancia.

Este resultado sugiere que las condiciones socioeconómicas continúan siendo un factor relevante para comprender las diferencias observadas en el desempeño matemático. Los hallazgos son consistentes con la literatura especializada, que sostiene que el origen social condiciona las oportunidades educativas, el acceso a recursos de aprendizaje y las trayectorias escolares de los estudiantes.

No obstante, es importante destacar que los modelos permiten identificar asociaciones relevantes entre variables y desempeño, pero no establecer relaciones causales. Por lo tanto, los resultados indican que el contexto socioeconómico posee una elevada capacidad explicativa dentro de los datos analizados, aunque no permiten afirmar que constituya por sí mismo la causa directa del rendimiento observado.

■ **Enfoque individual**

La segunda dimensión que emerge con fuerza corresponde al enfoque individual. Variables vinculadas a las actitudes, percepciones y características personales del estudiante aparecen de manera sistemática entre los principales predictores del desempeño.

Particularmente relevante resulta la variable `num_idx_actitud_matematica`, que ocupa posiciones destacadas en Random Forest y XGBoost tanto en las medidas de importancia interna como en los análisis de permutación y RFECV. Del mismo modo, `num_idx_autoeficacia_matematica` figura recurrentemente entre las variables más influyentes.

La importancia de estas variables sugiere que la relación subjetiva del estudiante con la matemática constituye un componente fundamental para comprender los resultados obtenidos. La percepción de competencia personal, la confianza para enfrentar problemas matemáticos y la disposición hacia la disciplina parecen desempeñar un papel tan relevante como algunas condiciones estructurales del contexto socioeconómico.

Asimismo, aparecen otras variables individuales y socioemocionales, tales como `num_idx_motivacion_aprendizaje`, `num_idx_habilidades_interpersonales`, `num_idx_perseverancia_academica` y `num_idx_actitud_lectura`. En conjunto, estos resultados respaldan la hipótesis de que el desempeño educativo depende no solamente de factores externos al estudiante, sino también de sus actitudes, expectativas y disposiciones frente al aprendizaje.

■ **Enfoque escolar**

Los resultados también aportan evidencia favorable al enfoque escolar. Entre las variables seleccionadas aparecen con frecuencia indicadores relacionados con el centro educativo y el grupo de pertenencia, tales como `categoria_centro`, `categoria_grupo`, `num_idx_esec_centro`, `num_idx_esec_grupo` y `num_idx_vinculo_estudiantes_docentes`.

La presencia de estas variables indica que el contexto institucional contiene información relevante para explicar diferencias en el desempeño matemático. Las características de los centros educativos, la composición de los grupos y las dinámicas de interacción dentro de la institución parecen influir sobre las trayectorias de aprendizaje de los estudiantes.

Sin embargo, estos resultados deben interpretarse con cautela. Las categorías institucionales pueden estar capturando simultáneamente diferencias socioeconómicas, culturales y territoriales entre los estudiantes que asisten a cada modalidad educativa. Por consiguiente, la importancia observada no debe interpretarse como evidencia causal sobre la superioridad o inferioridad de una modalidad educativa determinada.

■ **Enfoque familiar y cultural**

La evidencia asociada al enfoque familiar y cultural resulta menos directa. Entre las variables con mayor importancia no aparecen indicadores explícitos vinculados a la educación de

los padres, las expectativas familiares, la participación de la familia en el proceso educativo o el capital cultural del hogar.

Si bien algunas variables socioemocionales podrían estar reflejando parcialmente aspectos relacionados con el entorno familiar, los resultados obtenidos no permiten atribuir directamente a esta dimensión un papel tan destacado como el observado para los enfoques socioeconómico, individual y escolar.

Por lo tanto, dentro del conjunto de variables analizadas, la evidencia empírica para esta teoría aparece más débil o indirecta que para las restantes dimensiones consideradas.

6.2.2. Síntesis de los resultados arrojados por la Importancia de Variables

Considerando conjuntamente los tres modelos analizados, emerge un patrón consistente que combina tres dimensiones principales: el contexto socioeconómico del estudiante, sus características individuales y socioemocionales, y el contexto escolar en el que desarrolla su trayectoria educativa.

Un hallazgo particularmente relevante es que variables relacionadas con la actitud y la autoeficacia matemática presentan niveles de importancia comparables a los observados para los indicadores socioeconómicos. Esto sugiere que las desigualdades de origen no constituyen la única dimensión relevante para explicar el desempeño, sino que interactúan con factores motivacionales, emocionales y escolares.

Asimismo, la aparición recurrente de variables territoriales, particularmente algunas categorías de `departamento.residencia`, indica que existen diferencias geográficas que también contribuyen a explicar la heterogeneidad observada en los resultados. Estas diferencias probablemente reflejen una combinación de factores socioeconómicos, institucionales y culturales presentes en los distintos territorios del país.

Por otro lado, variables como género, ascendencia y país de nacimiento no aparecen de forma consistente entre las variables más importantes. Esto no implica que carezcan de relación con el desempeño educativo, sino que, una vez consideradas conjuntamente las demás variables incluidas en los modelos, su capacidad explicativa resulta comparativamente menor.

En términos generales, los resultados obtenidos a partir de los datos de la encuesta Aristas Media 2022 del INEE respaldan una visión multidimensional del desempeño educativo. La evidencia sugiere que los resultados en matemática dependen simultáneamente de las condiciones socioeconómicas de origen, de las características individuales de los estudiantes y del contexto institucional en el que desarrollan su proceso educativo. En consecuencia, las políticas orientadas a mejorar los aprendizajes matemáticos deberían contemplar intervenciones integrales que actúen sobre estas distintas dimensiones de manera complementaria.




Figura 7: Heatmap general

6.2.3. Análisis del HeatMap comparativo

Como etapa final del análisis de selección de variables se construyó un heatmap comparativo que permite integrar los resultados obtenidos mediante *Feature Importance*, *Permutation Importance* y *RFECV* para los tres modelos considerados. Para facilitar la comparación, las medidas de importancia fueron normalizadas y las variables fueron ordenadas de acuerdo con su importancia promedio global.

A diferencia de los análisis anteriores, cuyo objetivo fue examinar cada técnica de selección de manera individual, este gráfico permite evaluar la **consistencia de la importancia de las variables entre distintos modelos y métodos**. De esta forma, una variable que presenta valores elevados en varias columnas puede considerarse un predictor cuya relevancia resulta más robusta frente al método utilizado.

En primer lugar, se observa una concentración de valores elevados en las primeras filas del heatmap, correspondientes principalmente a los índices socioeconómicos y a las dimensiones individuales del estudiante. En particular, `num_idx_esec_alumno`, `num_idx_actitud_matematica` y `num_idx_autoeficacia_matematica` presentan niveles de importancia elevados en varias de las combinaciones de modelo y técnica. Este comportamiento resulta relevante porque muestra

que su importancia no depende exclusivamente de un único algoritmo o de una única medida de selección.

También se observa que variables asociadas al contexto socioeconómico del centro y del grupo, como `num_idx_esec_centro` y `num_idx_esec_grupo`, presentan valores elevados en diferentes especificaciones. Esto permite complementar el análisis realizado anteriormente, mostrando que la información relevante para explicar las diferencias en el desempeño no se concentra exclusivamente en las características individuales del alumno, sino que también se encuentra asociada al contexto educativo en el que se desarrolla su trayectoria.

Por otra parte, el heatmap permite identificar diferencias en la importancia asignada por cada técnica. Algunas variables presentan valores elevados únicamente en determinadas columnas, mientras que otras mantienen una importancia más estable. Esta diferencia resulta metodológicamente relevante: una variable puede ser útil para un algoritmo específico debido a la forma en que dicho modelo representa las relaciones entre los predictores, sin necesariamente constituir un factor robusto bajo todas las especificaciones.

En este sentido, el promedio utilizado para ordenar globalmente las variables no debe interpretarse como una nueva medida estadística de causalidad, sino como un mecanismo de **síntesis de evidencia**. Su finalidad es identificar aquellas variables cuya relevancia aparece de manera reiterada a través de diferentes aproximaciones de modelización.

Un aspecto particularmente destacable es que el ordenamiento global reproduce, en términos generales, las dimensiones que ya habían surgido como relevantes en los análisis individuales, pero permite observarlas desde una perspectiva conjunta. Esto proporciona mayor robustez al resultado, ya que la identificación de las variables principales no depende exclusivamente de las características de un único modelo.

Asimismo, la presencia de variables con importancia elevada en algunas técnicas y reducida en otras constituye un resultado en sí mismo. Esto evidencia que la selección de variables depende parcialmente de la interacción entre los predictores y de la estructura particular de cada algoritmo. Por este motivo, para el objetivo explicativo del trabajo resulta más relevante considerar la **convergencia entre métodos** que establecer un ranking basado exclusivamente en una única técnica.

En conjunto, el heatmap permite sintetizar los resultados de la etapa de selección de variables y proporciona el criterio para avanzar hacia una interpretación más parsimoniosa del fenómeno. A partir de esta evidencia se seleccionan aquellas variables que presentan mayor relevancia y consistencia global, las cuales serán posteriormente utilizadas como insumo para la construcción del árbol de decisión de baja complejidad orientado a la interpretación y comunicación de los resultados.

6.3. Árbol de decisión

Finalmente con el objetivo de presentar de una forma intuitiva los factores detrás del desempeño en matemática de los estudiantes, se optó por la construcción de un árbol de decisión sencillo, donde fijamos el hiperparámetro de profundidad en 3, resultando en el árbol de la figura 8 con los siguientes resultados:

Mejores hiperparámetros encontrados:

```
{'clasificador__criterion': 'gini',  
  'clasificador__max_depth': 3,  
  'clasificador__min_samples_leaf': 100,  
  'clasificador__min_samples_split': 50}
```

ROC AUC promedio en validación cruzada (5-folds): 0.8180




Figura 8: Modelo de Árbol de Decisión




Figura 9: Importancia de variables (Features) en el Árbol

7. Conclusiones y recomendaciones finales

Las conclusiones de este proyecto revelan una sólida y robusta concordancia entre todos los modelos predictivos y las metodologías de selección de características (feature selection) evaluadas. De manera sistemática, se identificaron dos grandes grupos de variables como los determinantes principales del desempeño estudiantil en matemática. En primer lugar, destacan los indicadores vinculados al contexto socioeconómico (`idx_inse_alumno`, `idx_esec_alumno`, `idx_esec_grupo` e `idx_esec_centro`). En segundo lugar, emerge con gran fuerza la disposición

psicológica del estudiante frente a la materia, representada por la actitud y la autoeficacia matemática (`idx_actitud_matematica` e `idx_autoeficacia_matematica`).

Esta convergencia de resultados se hace evidente al observar el heatmap comparativo de los modelos entrenados con sus mejores hiperparámetros, así como en la estructura del Árbol de Decisión, un modelo que fue utilizado en este trabajo por su alta interpretabilidad y capacidad de visualización directa. Asimismo, el rigor de estos hallazgos radica en que ratifican y potencian las tendencias preliminares que ya se habían detectado durante el Análisis Exploratorio de Datos (EDA).

A la luz de esta evidencia, resulta claro que para elevar significativamente el nivel de los estudiantes en matemática, las políticas públicas deben diseñarse de manera integral, abordando la problemática desde tres dimensiones de intervención complementarias:

1. Intervención estructural y socioeconómica: El primer nivel de acción debe trascender las paredes del aula. Dado el peso determinante del origen social en el éxito académico, es imperativa la implementación y el fortalecimiento de programas estatales de apoyo dirigidos a los sectores de menor nivel socioeconómico. Mejorar el rendimiento educativo requiere, como condición fundamental, mitigar las desigualdades de base mediante políticas que aseguren el acceso a una vivienda digna, salud integral e infraestructura comunitaria adecuada.

2. Apoyo psicopedagógico y socioemocional: La segunda dimensión debe enfocarse en la confianza del estudiante. Se vuelve fundamental integrar en los centros educativos programas de acompañamiento psicopedagógico. Estas iniciativas deben estar diseñadas para estimular la autoconfianza del alumnado frente a los desafíos lógicos, ayudando a derribar las barreras de frustración y el "miedo" histórico asociado a la abstracción matemática.

3. Transformación didáctica y enfoque práctico: En última instancia, la fuerte influencia de la actitud frente a la matemática invita a una profunda revisión de las metodologías de enseñanza. Es necesario repensar la didáctica de la asignatura, alejándose de modelos puramente teóricos para transitar hacia enfoques pedagógicos que prioricen la utilidad práctica. Contextualizar la matemática enseñando su aplicación en la resolución de problemas cotidianos es la clave para despertar un entusiasmo genuino en los estudiantes, transformando la materia en una herramienta atractiva y valiosa para su futuro.

Referencias

- [1] Instituto Nacional de Evaluación Educativa. *Ficha técnica: Bases de datos de la evaluación Aristas Media (año 2022)*. Inf. téc. Instituto Nacional de Evaluación Educativa, 2023. URL: https://www.ineed.edu.uy/wp-content/uploads/2023/08/Ficha-tecnica-Aristas-Media-2022_final.pdf.