

Universidad Católica del Uruguay (UCU) - Maestría en Ciencias de Datos

Trabajo Final - Aprendizaje Automático (ML)

Equipo: Lucas Barrios, Esteban Cardozo, Enrique De Martini

0) Importación de librerías y datos

Cargando datasets desde INEEd...

1) Reajuste de pesos

En esta parte del flujo se construye el peso final que se utilizará para las observaciones que sí cuentan con resultado de matemática. La idea es corregir el posible sesgo de selección que aparece cuando no todos los estudiantes tienen la misma probabilidad de haber rendido la prueba.

1. Se define una variable de participación:

$$R_i = \begin{cases} 1, & \text{si el estudiante } i \text{ rindió la prueba de matemática} \\ 0, & \text{si no la rindió} \end{cases}$$

Esta variable se calcula observando los NaNs de *Niveles_MAT*

2. Sobre todo el padrón completo se estima una probabilidad de participación mediante un modelo de propensión. Para esto se calculan por grupo, las proporciones de estudiantes que efectivamente rindieron la prueba:

$$\hat{p}_i = \frac{R_g}{Total_g}$$

Siendo $\hat{p}_i$ la probabilidad del estudiante i de haber realizado la prueba, R_g la cantidad de estudiantes de un grupo g que rindieron la prueba, y $Total_g$ la cantidad de estudiantes que figuran administrativamente como inscriptos en el grupo g . Para este cálculo se utiliza la variable **GrupoCodigoDes** que es el identificador único de los grupos de estudiantes.

3. Para las observaciones que sí tienen resultado de matemática, el peso original de la encuesta se ajusta dividiendo por esa probabilidad estimada:

$$w_i^{adj} = \frac{w_i^{orig}}{\hat{p}_i}$$

Esto compensa el hecho de que los estudiantes con menor probabilidad de rendir la prueba tienen menos representación en la muestra observada.

4. Para evitar que los pesos se vuelvan excesivamente grandes cuando $\hat{p}_i$ es muy pequeño, se impone un piso de estabilidad:

$$\hat{p}_i \leftarrow \max(\hat{p}_i, 0.05)$$

5. Finalmente, se normaliza el total de los pesos ajustados para que la suma siga siendo coherente con el total del padrón original:

$$\text{factor de normalización} = \frac{\sum_j w_j^{orig}}{\sum_{k: R_k=1} w_k^{adj}}$$

y por lo tanto:

$$w_i^{final} = \text{factor de normalización} \cdot w_i^{adj}$$

En resumen, el procedimiento busca reponderar las observaciones observadas para que representen mejor a la población total, aun cuando no todos los estudiantes cuentan con resultado de matemática.

1.1) Cálculo de pesos ajustados

Calculando pesos de propensión con probabilidad directa por grupo...

Observaciones en el padrón completo: 11546

Observaciones con MAT disponible: 9539

Observaciones iniciales (padron total): 11546

Observaciones finales (solo test MAT): 9539

Suma de pesos original: 11546.00

Suma de pesos ajustados: 11546.00

1.2) Construcción de dataframes de trabajo (X, y, w)

	zona	region	departamento_residencia	categoria_centro	categoria_grupo	alumno_genero
1	Montevideo	SUR	1.0	Secundaria pública	Secundaria pública	F
2	Montevideo	SUR	1.0	Secundaria pública	Secundaria pública	M
3	Interior	ESTE	10.0	UTU	UTU-CBT	F
4	Montevideo	SUR	1.0	Secundaria pública	Secundaria pública	M
5	Montevideo	SUR	2.0	Secundaria pública	Secundaria pública	M

2) Análisis exploratorio de datos (EDA)

2.1) Auditoría de datos

AUDITORIA DE VARIABLES DEL DATASET df_final_modelo


Dimensiones del dataset: 9539 filas × 37 columnas

	dtype	nulos	pct_nulos	valores_únicos	moda	e
zona	object	0	0.00	2	Interior	I
region	object	0	0.00	5	SUR	O
departamento_residencia	float64	612	6.42	20	1.0	6
categoria_centro	object	0	0.00	3	Secundaria pública	S
categoria_grupo	object	0	0.00	4	Secundaria pública	S
alumno_genero	object	93	0.97	3	M	M
ascendencia	float64	612	6.42	6	1.0	2
pais_nacimiento	float64	612	6.42	10	1.0	1
edad	float64	271	2.84	16	15.0	1
idx_inse_alumno	float64	633	6.64	80	39.0	3
idx_esec_alumno	float64	0	0.00	2088	-0.46526	-
idx_esec_centro	float64	0	0.00	339	-0.572519	-
idx_esec_grupo	float64	0	0.00	611	0.291839	0
idx_sentido_pertenencia	float64	682	7.15	661	52.058668	5
idx_vinculo_entre_estudiantes	float64	652	6.84	1112	56.84113	5
idx_vinculo_estudiantes_adscriptos	float64	660	6.92	1200	68.457301	5
idx_vinculo_estudiantes_docentes	float64	660	6.92	1038	52.919004	5
idx_voz_estudiante	float64	719	7.54	1286	47.812056	5
idx_actitud_lectura	float64	642	6.73	1287	50.992482	3
idx_actitud_matematica	float64	642	6.73	1261	69.693212	5
idx_autocontrol	float64	566	5.93	871	51.629505	4

	dtype	nulos	pct_nulos	valores_únicos	moda	e
idx_autoeficacia_idioma_espanol	float64	548	5.74	457	49.634164	4
idx_autoeficacia_matematica	float64	546	5.72	578	66.931399	4
idx_autoregulacion_metacognitiva	float64	545	5.71	1834	69.637535	4
idx_empatia	float64	556	5.83	762	50.546362	5
idx_conductas_externalizantes	float64	566	5.93	2357	36.697606	5
idx_habilidades_interpersonales	float64	556	5.83	8016	52.106994	5
idx_habilidades_intrapersonales	float64	565	5.92	8122	52.762366	3
idx_habilidades_relacionamiento	float64	557	5.84	1951	52.732579	5
idx_conductas_internalizantes	float64	566	5.93	5666	31.603074	5
idx_motivacion_aprendizaje	float64	545	5.71	8984	80.216373	4
idx_motivacion_intrinseca	float64	553	5.80	606	45.096011	4
idx_perseverancia_academica	float64	555	5.82	1459	50.311376	4
idx_regulacion_emocional	float64	565	5.92	1941	54.561106	3
idx_valoracion_tarea_idioma_espanol	float64	550	5.77	555	50.561581	5
idx_valoracion_tarea_matematica	float64	549	5.76	591	47.914845	4
target	int64	0	0.00	2	1.0	1

2.2) Barplots categóricos

Análisis de la tasa de desaprobación según variables categóricas
n = 9,539




A partir de los gráficos, se observa que la tasa global de desaprobación en la prueba de Matemática es elevada (88,7%), aunque existen diferencias entre los distintos grupos analizados.

- Zona de residencia: los estudiantes del Interior presentan una tasa de desaprobación superior a la media y mayor que la observada en Montevideo, lo que sugiere una leve brecha territorial en el desempeño.
- Región: se aprecian diferencias moderadas entre regiones. Norte, Este y Oeste exhiben las tasas de desaprobación más altas, mientras que la región Sur presenta la menor proporción de estudiantes desaprobados, ubicándose por debajo de la tasa global.
- Departamento de residencia: existe heterogeneidad entre departamentos. Algunos, como Artigas, muestran tasas de desaprobación cercanas al 97%, mientras que Montevideo y Durazno presentan valores relativamente menores. Sin embargo, en varios departamentos el tamaño muestral es reducido, por lo que esas diferencias deben interpretarse con cautela.
- Género: las diferencias son prácticamente inexistentes. Mujeres y varones presentan tasas de desaprobación muy similares, cercanas a la media, mientras que la categoría “Otro” se ubica levemente por debajo, aunque con un número muy pequeño de casos ($n=231$).
- Ascendencia: se observan algunas diferencias. Los estudiantes que se identifican con ascendencia asiática o amarilla presentan la mayor tasa de desaprobación, seguidos por quienes reportan ascendencia afro o negra y otra. En contraste, quienes declaran ascendencia blanca muestran la menor tasa de desaprobación del grupo, situándose por debajo de la media global.

2.3) Boxplots numéricos

Análisis de variables cuantitativas vs. Desaprobación / Aprobación (Boxplots)




A partir de los boxplots se observan diferencias claras entre los estudiantes que aprueban (0) y quienes desaprueban (1) la prueba de Matemática para algunos de los índices analizados.

- Estatus del nivel socioeconómico del estudiante: los estudiantes que aprueban presentan, en general, un nivel socioeconómico más alto. La mediana del índice es considerablemente superior en el grupo que aprueba, mientras que quienes desaprueban se concentran en valores más bajos. Esto sugiere una asociación negativa entre el nivel socioeconómico y la probabilidad de desaprobación.
- Índice del nivel cultural y socioeconómico del estudiante: se observa un patrón similar al anterior. Los estudiantes que aprueban presentan valores positivos y una mediana

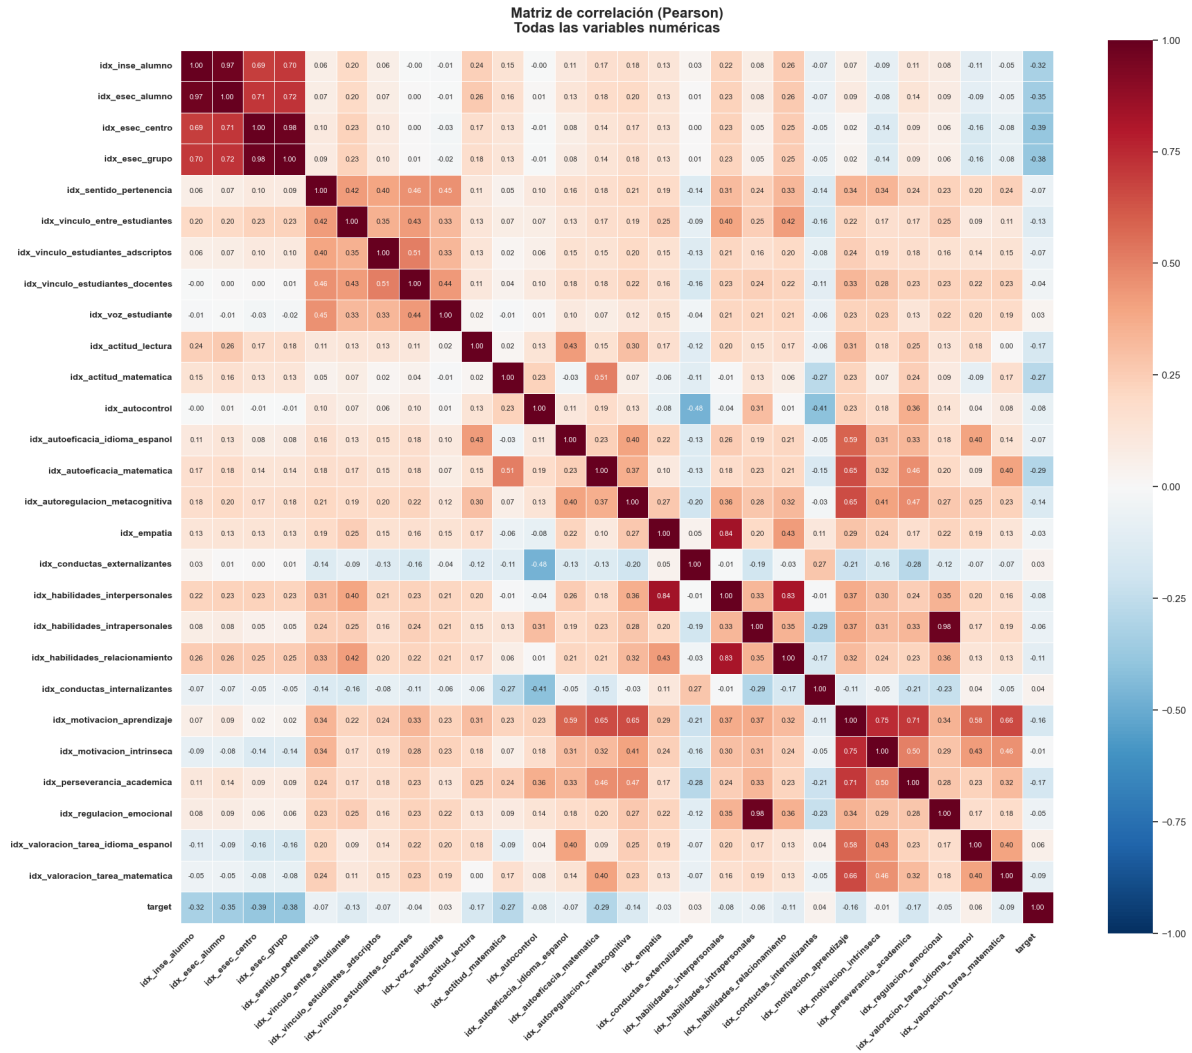
claramente superior, mientras que quienes desaprueban se concentran en valores inferiores. La diferencia entre ambos grupos es marcada, lo que indica que este índice podría ser un importante factor asociado al desempeño en Matemática.

- Índice de actitud hacia la matemática: los estudiantes que aprueban muestran una actitud más favorable hacia la asignatura, reflejada en una mediana sensiblemente mayor. Aunque existe cierto solapamiento entre ambos grupos, la distribución evidencia que una actitud más positiva hacia la Matemática se asocia con una menor probabilidad de desaprobación.
- Índice de vínculo entre estudiantes y docentes: las distribuciones de ambos grupos son muy similares, con medianas prácticamente iguales y una fuerte superposición de los rangos intercuartílicos. Esto sugiere que, de manera aislada, este indicador presenta una capacidad limitada para diferenciar entre estudiantes que aprueban y desaprueban.
- Índice de sentido de pertenencia: también se observan diferencias reducidas entre ambos grupos. Los estudiantes que aprueban presentan una mediana ligeramente superior, aunque la superposición entre las distribuciones es considerable, por lo que el sentido de pertenencia parece tener una asociación más débil con el resultado de la prueba.

2.4) Barplots numéricos



2.5) Correlaciones lineales



Ranking de correlación de índices socioemocionales vs Target



Análisis de correlaciones con la tasa de desaprobación (target)

- Los factores socioeconómicos y educativos (idx_inse_alumno e idx_esec_alumno) son

los que más se asocian (aunque de forma moderada) con la desaprobación: a mejores índices, menor tasa de desaprobación.

- La actitud hacia matemáticas tiene cierta influencia, pero es más débil que los factores estructurales.
- El vínculo con docentes y el sentido de pertenencia tienen una correlación casi nula con la desaprobación, lo que sugiere que, en este contexto, no son factores determinantes para explicar el rendimiento en términos de aprobación/desaprobación.
- No hay correlaciones fuertes (todas están por debajo de 0.4 en valor absoluto), lo que indica que la desaprobación es un fenómeno multifactorial y que estas variables explican solo una parte de su variabilidad.

Durante el análisis exploratorio (EDA), se identificó la presencia de valores atípicos (e.g., códigos 98 y 99) en variables sociodemográficas como la Ascendencia. Dado que el diccionario de datos oficial del INEEd solo categoriza respuestas del 1 al 5, se infirió que estos códigos corresponden a marcas de sistema para ‘No sabe/No contesta’. En consecuencia, fueron transformados a nulos (NaN) para permitir un manejo correcto en el Pipeline de imputación y no distorsionar la evaluación de equidad algorítmica.

Para el INEEd cada nivel describe qué es capaz de hacer el estudiante en términos de complejidad cognitiva, basándose en los programas oficiales de ANEP: - B1 y Nivel 1: El estudiante solo puede resolver tareas matemáticas muy elementales, rutinarias y con información explícita. - Nivel 2: Logra resolver problemas simples de un solo paso o extraer datos directos de tablas y gráficos. - Nivel 3: Es considerado habitualmente el nivel de transición o el umbral de competencia básica esperada. El estudiante puede resolver problemas que requieren relacionar algunos datos o hacer cálculos secuenciales sencillos. - Niveles 4 y 5: El estudiante demuestra una consolidación profunda. Es capaz de modelizar matemáticamente situaciones de la vida real, resolver problemas no rutinarios, interpretar conceptos algebraicos y argumentar sus respuestas.

La binarización aplicada responde a una mirada de política pública orientada a la excelencia y consolidación real de los aprendizajes, donde el “rendimiento satisfactorio” no es solo “saber lo mínimo indispensable” (Nivel 3), sino tener la robustez cognitiva (Niveles 4 y 5) necesaria para continuar trayectorias educativas complejas sin rezago.

3) Entrenamiento de los modelos

3.1) Categorización de variables

3.2) Column transformers

3.3) Definición de modelos y corrida

Entrenando Regresion_Logistica...

Entrenando Random_Forest...

Entrenando XGBoost...

3.4) Resultados de los modelos

--- Comparación de Modelos (ROC-AUC en Validación Cruzada) ---

Modelo: Regresion_Logistica
Score (ROC-AUC): 0.8814
Hiperparámetros elegidos:
- clasificador__C: 0.1
- clasificador__l1_ratio: 0.0

Modelo: Random_Forest
Score (ROC-AUC): 0.8747
Hiperparámetros elegidos:
- clasificador__max_depth: 12
- clasificador__min_samples_leaf: 10
- clasificador__min_samples_split: 20
- clasificador__n_estimators: 200

Modelo: XGBoost
Score (ROC-AUC): 0.8840
Hiperparámetros elegidos:
- clasificador__learning_rate: 0.1
- clasificador__max_depth: 3
- clasificador__n_estimators: 200

- clasificador_subsample: 0.8

3.5) Cálculo de Feature y Permutation Importance

3.6) Cálculo de RFECV

Ejecutando RFECV para: Regresion_Logistica

- Features seleccionadas: 64
- Mejor ROC-AUC CV (RFECV): 0.8797

Ejecutando RFECV para: Random_Forest

- Features seleccionadas: 65
- Mejor ROC-AUC CV (RFECV): 0.8777

Ejecutando RFECV para: XGBoost

- Features seleccionadas: 57
- Mejor ROC-AUC CV (RFECV): 0.8819


4) Gráficas comparativas

4.1) Top 10 (Internas, Permutación, RFECV)


TOP VARIABLES SELECCIONADAS POR CADA MODELO (RFECV)

	Regresion_Logistica	Random_Forest	XGBoost
Rank 1	num__idx_esec_alumno	num__idx_actitud_matematica	num__idx_e
Rank 2	cat__departamento_residencia_2.0	num__idx_esec_centro	num__idx_e
Rank 3	cat__categoria_grupo_UTU-FPB	num__idx_esec_alumno	num__idx_a
Rank 4	num__idx_inse_alumno	num__idx_autoeficacia_matematica	cat__categor
Rank 5	cat__departamento_residencia_16.0	num__idx_esec_grupo	num__idx_a
Rank 6	cat__departamento_residencia_5.0	num__idx_inse_alumno	cat__categor
Rank 7	num__idx_autoeficacia_matematica	cat__categoria_grupo_Secundaria privada	num__idx_e
Rank 8	num__idx_actitud_matematica	num__idx_motivacion_aprendizaje	cat__categor
Rank 9	num__idx_esec_centro	num__idx_actitud_lectura	num__idx_a
Rank 10	cat__departamento_residencia_19.0	num__idx_perseverancia_academica	cat__categor

Análisis Integral de Importancia de Variables: Interna vs Permutación vs RFECV



4.1) Heatmap (Internas, Permutacion, RFECV)



5) Análisis explicativo complementario

5.1) Entrenamiento de árbol de decisión corto

Buscando el mejor árbol de decisión sobre el dataset completo...

Fitting 5 folds for each of 18 candidates, totalling 90 fits

Mejores hiperparámetros encontrados:

